

Universidad Mayor de San Andres

Maestria en Inteligencia Artificial y Ciencia de Datos

Reporte Final Integrado

Proyecto de Identificacion de Clientes Premium sobre Olist

Modulo de Implementacion de Soluciones de Inteligencia Artificial

Marcelo de la Quintana

Gaston Nina

Gerick Toro

Junio 2026

Índice

Presentacion	2
1. Sprint 1: Perfilado, EDA y Baseline	2
2. Sprint 2: Pipeline y Features	7
3. Sprint 3: Modelo Final y HPO	13
4. Sprint 4: MVP, Holdout y Gobernanza	20

Presentacion

Este documento consolida en un unico entregable los cuatro informes tecnicos del proyecto. Para preservar fidelidad academica y trazabilidad, cada sprint se incorpora como su reporte oficial completo, manteniendo su estructura, tablas, figuras y conclusiones originales.

1. Sprint 1: Perfilado, EDA y Baseline

Reporte de Sprint 1: Perfilado de Datos Crudos, Exploración y Modelo Baseline para la Identificación de Clientes Premium

Marcelo de la Quintana, Gaston Nina, y Gerick Toro
Módulo de Implementación de Soluciones de Inteligencia Artificial
Maestría en Inteligencia Artificial y Ciencia de Datos

Resumen—Este informe presenta el desarrollo del Sprint 1 para el Caso de Estudio 3 del proyecto analítico aplicado sobre la plataforma de comercio electrónico Olist. El objetivo es diseñar y evaluar un Producto Mínimo Viable (MVP) para la clasificación supervisada de clientes Premium (*is_premium*). Realizamos un perfilado profundo sobre los siete datasets crudos de Olist, identificando y documentando fallas estructurales e inconsistencias cronológicas en el ciclo de vida de los pedidos. Justificamos empíricamente, mediante análisis de asimetría (*skewness*), la fijación de la variable objetivo en el percentil 80 del gasto acumulado neto del cliente único (205,18\$ USD). Por último, entrenamos un modelo baseline de regresión logística libre de fuga de datos (*data leakage*), que arrojó un ROC-AUC de 0,5355. Este resultado experimental demuestra la denominada “Paradoja del Target”, caracterizada por compras únicas de alto costo en lugar de recurrencia en el 97 % de la base de clientes, sentando las directrices de ingeniería de características para el Sprint 2.

Index Terms—Clientes Premium, Olist, Calidad de Datos, Fuga de Datos, Regresión Logística, Perfilado de Datos.

I. INTRODUCCIÓN

LA correcta identificación de clientes de alto valor, comúnmente denominados clientes Premium, es un factor estratégico crucial en la optimización de los ingresos de plataformas de comercio electrónico. Tradicionalmente, las campañas de retención y marketing de fidelización sufren ineficiencias de segmentación al utilizar criterios arbitrarios basados únicamente en promedios transaccionales o en reglas de negocio estáticas que ignoran el perfilamiento temporal.

El presente informe detalla la entrega del **Sprint 1** para el desarrollo de una solución supervisada de Inteligencia Artificial que predice la pertenencia de un cliente al segmento Premium en Olist. Se abordan la conceptualización del problema de negocio, el análisis descriptivo y perfilado de la calidad física y temporal de los datos crudos, la justificación cuantitativa para la modelación de la variable objetivo, y la evaluación experimental del primer modelo clasificador de referencia (baseline).

II. DEFINICIÓN DEL PROBLEMA Y OBJETIVO DEL MVP

II-A. Problema de Negocio y Segmentación

El e-commerce brasileño Olist funciona como un integrador de múltiples vendedores locales (*marketplaces*). En este modelo operativo, los clientes de alta facturación y frecuencia representan la mayor fracción del margen bruto de la compañía. Sin embargo, debido a la falta de un scoring predictivo

dinámico, la plataforma carece de la habilidad de identificar anticipadamente a aquellos clientes propensos a convertirse en usuarios recurrentes de alto valor, perdiendo oportunidades de venta cruzada y retención personalizada.

II-B. Objetivo del MVP

El Producto Mínimo Viable (MVP) tiene como objetivo clasificar de forma mensual si un cliente único (*customer_unique_id*) pertenece al segmento Premium (*is_premium = 1*) a partir de su historial inicial de compra, comportamiento de pago e interacciones de servicio. El valor del MVP1 radica en establecer un flujo de preprocesamiento de datos limpio y un baseline técnico robusto sobre el cual iterar algoritmos de mayor capacidad (como Random Forest o XGBoost) en los siguientes sprints.

II-C. Formulación de Hipótesis Iniciales

Con el fin de guiar la exploración analítica y el modelado predictivo, se definieron cinco hipótesis de negocio iniciales que contrastan el comportamiento esperado del cliente premium frente a la base general:

- **H1 (Frecuencia):** Los clientes con mayor frecuencia de compra acumulada en la plataforma tienen una probabilidad significativamente mayor de ser catalogados como Premium.
- **H2 (Calificaciones):** Los clientes con puntuaciones promedio de reseñas más altas muestran una mayor afinidad con la marca y tienden a pertenecer al segmento Premium.
- **H3 (Recencia):** Los clientes con menor recencia temporal (compras más recientes) poseen una mayor probabilidad de ser Premium.
- **H4 (Monetario):** Los clientes del segmento Premium presentan tickets promedio unitarios significativamente superiores en comparación con los clientes normales.
- **H5 (Poder Predictivo RFMT):** Las variables transaccionales de comportamiento temporal y de servicio (RFMT) son suficientes por sí solas para entrenar un clasificador discriminante efectivo de clientes Premium.

III. PERFILADO DE DATOS CRUDOS (EDA INICIAL)

El proceso de perfilado de datos crudos involucró la ingesta e inspección de los siete datasets de Olist: clientes, órdenes,

pagos, calificaciones (reviews), productos, vendedores e ítems de compra. Se consolidó una dimensión total inicial de 99,441 clientes únicos y 112,650 ítems de compra registrados entre septiembre de 2016 y octubre de 2018 (772 días).

III-A. Verificación de Valores Faltantes

El análisis de completitud, visualizado mediante diagramas de barras e matrices de distribución de nulos, arrojó nulos lógicos únicamente en variables operacionales y subjetivas de los pedidos y reseñas. En la Tabla I se describen los nulos clave analizados.

Cuadro I
VALORES FALTANTES CRÍTICOS EN DATASETS CRUDOS

Variable	Registros Nulos	Proporción (%)
review_comment_title	87,656	88.34
review_comment_message	58,247	58.70
order_delivered_customer_date	2,965	2.98
order_delivered_carrier_date	1,783	1.79
product_category_name	610	1.85
order_approved_at	160	0.16

III-B. Auditoría de Inconsistencias Temporales

Un aporte crucial del análisis de perfilado de calidad de datos fue la validación de coherencia lógica cronológica en el ciclo de vida del pedido. Mediante pruebas de consistencia en el dataset orders, se identificaron fallas físicas en los logs del sistema origen:

- **Carrier antes de compra:** 166 pedidos tienen fecha de recogida del transportista (order_delivered_carrier_date) registrada como anterior a la fecha de compra del pedido.
- **Carrier antes de aprobación:** 1,359 registros reportan envío al transportista antes de la aprobación del pago (order_approved_at).
- **Entrega al cliente antes que el transportista:** 23 órdenes figuran como recibidas por el cliente antes de ingresar al sistema logístico de transporte.
- **Entrega al cliente antes de aprobación:** 61 órdenes reportan recepción definitiva por parte del usuario final antes de que el pago del pedido fuese aprobado.

III-C. Distribución de Estados de Pedidos

El ciclo de vida de los pedidos se analizó cuantitativamente. Como se muestra en la Tabla II, el 97,02% de las compras registradas logran el estado final de entregado (delivered).

III-D. Análisis de Asimetría Financiera

Las variables transaccionales de precios y costos de fletes de los artículos muestran distribuciones de cola larga fuertemente sesgadas hacia la derecha. Al evaluar su asimetría matemática (skewness), se confirmaron valores críticos:

- **Asimetría de Precios:** 7,9231
- **Asimetría de Fletes:** 5,6398

Este comportamiento de asimetría extrema (mayor a 7,0) fundamenta empíricamente que el uso de promedios simples

Cuadro II
DISTRIBUCIÓN DEL ESTADO DE LAS ÓRDENES

Estado	Frecuencia	Proporción (%)
delivered	96,478	97.020
shipped	1,107	1.113
canceled	625	0.628
unavailable	609	0.612
invoiced	314	0.315
processing	301	0.302
created	5	0.005
approved	2	0.002

para definir el corte del segmento Premium distorsionaría el análisis debido al impacto de valores atípicos. Esto justifica el empleo de percentiles robustos sobre el gasto acumulado neto del cliente único.

La Figura 1 ilustra la distribución del gasto acumulado por cliente, donde se aprecia la marcada cola derecha y la posición del umbral del Percentil 80 (\$205.18 USD) que define la variable objetivo.




Figura 1. Distribución del gasto acumulado neto por cliente. La línea discontinua indica el umbral del Percentil 80 (\$205.18 USD), adoptado como corte para *is_premium* dado el sesgo extremo de la distribución (skewness = 7,92).

IV. JUSTIFICACIÓN DE VARIABLES Y TARGET

IV-A. Consolidación a nivel Cliente Único

La Master Table consolidada se agrupó al nivel del identificador único de cliente (customer_unique_id) en lugar de usar customer_id (asociado a cada pedido individual). La unificación geográfica de estados y códigos postales se resolvió seleccionando el registro más reciente para cada usuario, evitando duplicidad e infrecuencias.

IV-B. Definición de Variable Objetivo

El target preliminar se define como:

$$is_premium = \begin{cases} 1 & \text{si } total_spent \geq \text{Percentil } 80 \\ 0 & \text{en caso contrario} \end{cases} \quad (1)$$

El umbral calculado del percentil 80 se sitúa en **\$205.18 USD** de facturación neta real. Esto segmenta de forma balanceada al 20,003 % (19,222 clientes) como Premium y al 79,997 % (76,874 clientes) como Regulares.

IV-C. Mitigación del Data Leakage

Para el entrenamiento del baseline, se excluyeron directamente las variables `total_spent` y `avg_ticket`, dado que la variable objetivo se calcula a partir del gasto neto. Incluirlas representaría una fuga de datos directa, lo que inflaría el ROC-AUC al 100 % sin valor predictivo real.

Las características seleccionadas para el modelado corresponden a variables operacionales y de experiencia: cantidad de órdenes (`total_orders`), recencia en días (`recency_days`), lifetime del cliente en la plataforma (`customer_lifetime_days`), calificación promedio (`avg_review_score`), indicador binario de reseña ausente (`review_is_missing`), tasa de entregas tardías (`late_delivery_rate`) y cantidad de métodos de pago (`payment_methods_count`). Para el diseño de estas variables temporales y transaccionales, nos fundamentamos en la metodología RFMT (Recency, Frequency, Monetary, and Time) descrita en [1].

V. EVALUACIÓN EXPERIMENTAL Y BASELINE

V-A. Diseño Experimental Libre de Leakage

Para evitar fuga de información en el proceso de preprocesamiento, se implementó el siguiente pipeline secuencial:

1. División en conjunto de entrenamiento (70 %) y prueba (30 %).
2. Cálculo de la media del score de reseñas únicamente en entrenamiento ($\sim 4,08$) para imputar valores nulos de forma neutral en ambos conjuntos.
3. Imputación por mediana para variables operacionales basándose exclusivamente en el conjunto de entrenamiento.
4. Ajuste del escalador `StandardScaler` sobre entrenamiento y posterior transformación a prueba.

V-B. Resultados y Reporte de Clasificación

Se entrenó una regresión logística simple con ponderación de clase balanceada para contrarrestar el desbalance de clases del target (80/20). Las métricas resultantes sobre el test set (28,829 clientes) se resumen en la Tabla III.

Cuadro III
REPORTES DE CLASIFICACIÓN DEL BASELINE

Clase	Precision	Recall	F1-Score	Soporte
Regular (0)	0.81	0.91	0.86	23,062
Premium (1)	0.30	0.16	0.21	5,767
ROC-AUC			0.5355	28,829

V-C. Curva ROC del Modelo Baseline

La Figura 2 presenta la curva ROC del modelo de regresión logística entrenado. Se puede observar que la curva se aleja apenas del clasificador aleatorio, coherente con el valor de ROC-AUC = 0,5355 reportado en la Tabla III.




Figura 2. Curva ROC del modelo baseline (regresión logística con clase balanceada). El área bajo la curva (AUC = 0,5355) es marginalmente superior al clasificador aleatorio, evidenciando la insuficiencia de las variables RFMT tradicionales para discriminar el segmento Premium.

V-D. La Paradoja del Target

El modelo baseline técnico presenta un rendimiento muy modesto ($ROC - AUC = 0,5355$), apenas superior a una asignación aleatoria. Este resultado confirma empíricamente la **Paradoja del Target** y contradice la hipótesis de predictibilidad básica **H5**: el comportamiento de compra de clientes Premium en Olist está determinado por una **compra única de alto valor** y no por una conducta de alta frecuencia y lealtad temporal. Las variables basadas estrictamente en la frecuencia de pedidos (`total_orders`) o el lifetime de relación (`customer_lifetime_days`) son idénticas para el 97 % de los clientes (con solo 1 orden), impidiendo la diferenciación estadística usando únicamente RFM tradicional (contradiciendo la hipótesis **H1**).

V-E. Métricas y Relaciones de Negocio

El análisis descriptivo de segmentos revela valiosas relaciones comerciales que contrastan nuestras hipótesis iniciales:

- **Ticket Medio (Validación H4):** El ticket promedio del cliente Regular es de 93,99\$ USD, mientras que en el segmento Premium alcanza **\$416.14 USD** (4,4 veces superior). Esto valida plenamente la hipótesis **H4**, confirmando la concentración monetaria del segmento.
- **Satisfacción en Clientes Premium (Validación H2):** Las reseñas promedio de los clientes Premium son sutilmente **menores** (4,04 estrellas) frente a los clientes normales (4,10). Esto contradice la hipótesis de mayor satisfacción **H2**, revelando que los clientes de alto ticket poseen expectativas superiores y menor tolerancia ante fallas.

- **Retrasos Logísticos (Validación H3):** El porcentaje de entregas con retraso (`late_delivery_rate`) es del **8.87 %** en el grupo Premium frente al 7,67 % en clientes regulares. Esto contradice la hipótesis logística de priorización **H3**, lo que corrobora que las compras caras involucran productos de mayor tamaño y complejidad de distribución, elevando los retrasos.

VI. CONCLUSIONES Y PRÓXIMOS PASOS

La culminación del Sprint 1 certifica la viabilidad inicial del proyecto. El análisis descriptivo evidenció que el modelado tradicional de comportamiento transaccional es insuficiente para clasificar clientes Premium dado el bajo volumen de recompras de la plataforma.

Para resolver este desafío en el **Sprint 2**, la estrategia técnica se enfocará en:

1. **Características de Categoría:** Extraer el tipo de producto (tecnología, computación y muebles concentran el gasto) e incorporarlo al modelo.
2. **Features de Financiamiento:** Codificar el método de pago (`main_payment_type`) y la cantidad de cuotas (`payment_installments`).
3. **Modelos No Lineales:** Entrenar y evaluar Random Forest y XGBoost.

REFERENCIAS

- [1] A. Ullah, M. I. Mohmand, H. Hussain, S. Johar, I. Khan, S. Ahmad, H. A. Mahmoud, and S. Huda, "Customer Analysis Using Machine Learning-Based Classification Algorithms for Effective Segmentation Using Recency, Frequency, Monetary, and Time," *Sensors*, vol. 23, no. 6, p. 3180, Mar. 2023. [Online]. Available: <https://doi.org/10.3390/s23063180>

2. Sprint 2: Pipeline y Features

Reporte de Sprint 2: Pipeline Reproducible de Ingeniería de Variables y Clasificación de Clientes Premium

Marcelo de la Quintana, Gaston Nina, y Gerick Toro
Módulo de Implementación de Soluciones de Inteligencia Artificial
Maestría en Inteligencia Artificial y Ciencia de Datos

Resumen—Este informe documenta el Sprint 2 del proyecto analítico sobre la plataforma Olist, cuyo objetivo central fue transformar el trabajo exploratorio del Sprint 1 en un pipeline modular y reproducible para la clasificación supervisada de clientes Premium (*is_premium*). Se migró la lógica del notebook histórico hacia cuatro scripts independientes en `src/`, se construyeron 18 nuevas variables operativas, logísticas, de cuotas y categoría, y se ejecutaron 8 experimentos de selección de variables con control explícito de fuga de información (*data leakage*). El experimento ganador (`corr_le_0.85`) seleccionó 28 features mediante filtro de correlación, con una diferencia en AUC-ROC de validación de apenas 0.0018 respecto al conjunto inicial de 37 features, a cambio de menor redundancia y mayor parsimonia. La evaluación final sobre un split temporal muestra mejoras sustanciales frente al baseline del Sprint 1 en todas las métricas clave: ROC-AUC pasa de 0.5355 a 0.7929, el F1-score de 0.21 a 0.54 y el Gini de 0.071 a 0.586. Los KPIs confirman que el segmento premium (20 % de 96.096 clientes) concentra el 56.03 % de la facturación observada, con un ticket promedio 4.36 veces superior al del cliente regular. Una simulación sobre el periodo de holdout (ago-oct 2018, 6.468 clientes activos) valida la estabilidad del umbral fijo: tasa premium de 19.37 % y ratio de ticket de 4.47x, coherentes con los valores del conjunto *dev*.

Index Terms—Pipeline Reproducible, Ingeniería de Variables, Selección de Variables, Clientes Premium, Olist, Fuga de Datos, Random Forest, ROC-AUC.

I. INTRODUCCIÓN

EL Sprint 1 estableció la viabilidad inicial del proyecto mediante la exploración de los datos crudos de Olist, la definición del target *is_premium* como etiqueta binaria basada en el percentil 80 del gasto acumulado de pedidos entregados, y la evaluación de un modelo baseline de regresión logística que arrojó un ROC-AUC de 0.5355. Este resultado evidenció la **Paradoja del Target**: el 97 % de los clientes posee una sola orden, por lo que las variables RFMT tradicionales de frecuencia y lifetime son prácticamente idénticas para el segmento premium y el regular.

El objetivo del **Sprint 2** fue resolver esa paradoja construyendo un conjunto enriquecido de variables de comportamiento, logística, método de pago y categoría de producto, y organizarlas en un pipeline modular que sea auditable, versionado y reproducible sin depender de la ejecución manual de notebooks.

I-A. Principio Rector del Sprint

Los notebooks históricos del Sprint 1 se mantienen como evidencia sin modificación. El Sprint 2 construye un flujo

separado en `src/` con tres capas conceptuales:

1. **Evidencia histórica**: notebooks de Sprint 1 intactos.
2. **Pipeline reproducible**: scripts en `src/data/` y `src/features/`.
3. **Exposición analítica**: notebook integrador que consume artefactos, sin regenerarlos.

II. ARQUITECTURA DEL PIPELINE Y DAG

II-A. Estructura General

El pipeline del Sprint 2 se organiza en cuatro capas funcionales con dependencias explícitas y artefactos intermedios persistidos en `data/interim/` y `data/processed/`. El orden de ejecución reproducible es:

1. `src/data/build_master_table.py`
2. `src/features/build_rfm_features.py`
3. `src/features/feature_selection_experiments.py`
4. `src/models/evaluate_model.py`

II-B. Entradas y Salidas por Etapa

La Tabla I resume los scripts, entradas y salidas principales de cada capa.

Cuadro I
RESUMEN DE ETAPAS DEL DAG — SPRINT 2

Etapa	Script	Entrada	Salidas principales
Master table	<code>build_master_table.py</code>	<code>{perf }/r.parquet</code>	<code>01_raw_{perf }.parquet</code> , <code>02_clean_{perf }.parquet</code> , <code>threshold.json</code>
Features	<code>build_rfm_features.py</code>	<code>03_clean_{perf }.parquet</code>	<code>05_features_rfm.parquet</code>
Selección	<code>feature_selection_experiments.py</code>	<code>05_features_rfm.parquet</code>	<code>06_experiment3.parquet</code> , <code>06_selected.parquet</code>
Evaluación	<code>evaluate_model.py</code>	<code>06_selected.parquet</code>	<code>08_evaluation_metrics.json</code>
Análisis	<code>02_pipeline_features.ipynb</code>	Todos los artefactos	Gráficas, narrativa

II-C. Decisiones Clave del DAG

Cuatro decisiones de diseño son relevantes para la trazabilidad y defensa del pipeline:

- El script `select_features.py` fue deprecado. La fuente oficial de `06_features_selected.parquet` es `feature_selection_experiments.py`, para garantizar que la selección final esté respaldada por experimentación con métricas y no por criterio manual.
- El corte temporal oficial para selección y evaluación es **2018-07-01**. Se descartó *2018-08-01* porque la fecha máxima de `last_purchase` en el split *dev* es 2018-07-31, lo que dejaba el conjunto de validación vacío.

- El umbral del target se calcula una sola vez sobre la población *dev* (**P80 = BRL 197.01**) y se persiste en modo *fit*. Las corridas posteriores usan el modo *apply* sin recalcular, garantizando comparabilidad entre experimentos.
- Los artefactos de la master table usan un prefijo de perfil en el nombre (*_dev*, *_holdout*, *_raw*) para evitar colisiones entre ejecuciones sobre distintos conjuntos de datos. El script orquestador `scripts/build_features.sh` corre el pipeline completo: pasos 1–4 sobre el split *dev* y pasos 5–6 sobre el *holdout* con umbral en modo *apply*.

III. MASTER TABLE Y DEFINICIÓN DEL TARGET

III-A. Construcción de la Master Table

La lógica del notebook `01_build_master_table.ipynb` del Sprint 1 fue migrada al script `src/data/build_master_table.py`. Las reglas principales son:

- Granularidad final por *customer_unique_id*.
- Métricas financieras basadas exclusivamente en pedidos con estado *delivered*.
- Métricas operativas calculadas sobre todas las órdenes disponibles del cliente.
- Imputación mínima a 0 para conteos y sumas clave.

La master table raw (96.096×32 columnas) expuso valores faltantes en variables financieras y de comportamiento. Las columnas con mayor porcentaje de nulos se muestran en la Tabla II.

Cuadro II

VARIABLES CON MAYOR PORCENTAJE DE NULOS — MASTER TABLE RAW

Variable	Nulos	% Nulos
<i>avg_delivery_days</i>	8.884	9.24 %
<i>total_spent / avg_ticket</i>	8.882	9.24 %
<i>top_category</i>	8.205	8.54 %
<i>avg_review_score</i>	6.966	7.25 %
<i>max_item_price</i>	6.914	7.19 %
<i>payment_methods_count</i>	6.278	6.53 %

Tras la limpieza (Fase 4), la master table limpia quedó con **96.096 filas × 33 columnas** y **cero duplicados** por *customer_unique_id*.

III-B. Definición y Defensa del Target

El target *is_premium* se mantiene como etiqueta binaria sobre gasto acumulado de pedidos entregados, con umbral fijo:

$$is_premium = \begin{cases} 1 & \text{si } total_spent \geq P80_{dev} = 197,01 \\ 0 & \text{en caso contrario} \end{cases} \quad (1)$$

Esta definición produce una tasa premium del **20.00 %** (19.220 clientes) sobre 96.096 clientes totales. Las justificaciones metodológicas son:

- **Por qué P80:** conserva un segmento interpretable del $\sim 20 \%$, consistente con la lógica de segmentación de alto

valor; ni demasiado amplio (P75) ni demasiado estrecho (P90). Los KPIs de negocio validan la elección: ese 20 % explica el 56.03 % de la facturación.

- **Por qué umbral fijo:** evita que el target cambie en cada corrida del pipeline, manteniendo comparabilidad entre experimentos y corridas futuras con nueva data.
- **Por qué excluir cancelaciones:** el target representa valor efectivamente realizado, no intención de compra. Incluir pedidos no entregados mezclaría ingreso concretado con operaciones fallidas.

IV. INGENIERÍA DE VARIABLES

IV-A. Nuevas Variables Creadas

El módulo `src/features/build_rfm_features.py` generó **18 variables nuevas** sobre la master table limpia, agrupadas por dimensión en la Tabla III.

Cuadro III
VARIABLES NUEVAS CREADAS EN EL SPRINT 2

Dimensión	Variables
Composición de pedido	<i>items_per_order</i> , <i>products_per_order</i> , <i>max_to_avg_price_ratio</i>
Flete	<i>freight_to_item_ratio</i>
Cuotas	<i>installments_gt_1_flag</i> , <i>installments_gt_6_flag</i>
Método de pago	<i>credit_card_flag</i> , <i>boleto_flag</i> , <i>voucher_flag</i> , <i>payment_complexity_flag</i>
Logística	<i>has_late_delivery</i> , <i>has_cancellation</i> , <i>delivery_gap</i>
Reseñas	<i>reviews_per_order</i>
Geografía	<i>region_group</i> , <i>far_region_flag</i>
Categoría	<i>top_category_group</i> , <i>top_category_is_high_value</i>

El dataset de features (`05_features_rfm.parquet`) resultante tiene 96.096 filas y 51 columnas, con cero duplicados y cero nulos en las variables nuevas.

IV-B. Control de Leakage en la Construcción de Variables

La variable *top_category_is_high_value* merece mención especial: para evitar fuga del target, se definió con el cuartil superior de *avg_item_price* por categoría, y **no** con la tasa premium de la categoría (que reconstruiría parcialmente *is_premium*).

V. SELECCIÓN EXPERIMENTAL DE VARIABLES

V-A. Metodología

La selección manual fue usada únicamente como saneamiento preliminar para excluir:

- Proxies monetarias directas del target: *total_spent*, *avg_ticket*, *avg_order_price*, *avg_item_price*, *max_item_price*, *avg_freight_value*, *avg_freight_ratio*, *freight_to_item_ratio*.
- Identificadores: *customer_unique_id*, *customer_city*, *customer_zip_code_prefix*.
- Fechas crudas: *first_purchase*, *last_purchase*.

La selección final se justificó mediante **8 experimentos reproductibles**, usando un RandomForest con split temporal (train: *last_purchase* < 2018-07-01 = 83.589 filas; validation: $\geq$ 2018-07-01 = 6.230 filas). El train fue submuestreado estratificadamente a 30.000 filas para agilizar las corridas.

Cuadro IV
RESULTADOS DE EXPERIMENTOS DE SELECCIÓN DE VARIABLES

Experimento	Método	# Feat	AUC Train	AUC Val	Gini Val
initial	initial	37	0.8172	0.7939	0.5878
missing_le_0.10	missing	37	0.8172	0.7939	0.5878
corr_le_0.90	correlation	29	0.8152	0.7923	0.5846
corr_le_0.95	correlation	32	0.8170	0.7922	0.5845
corr_le_0.85 *	correlation	28	0.8172	0.7921	0.5843
univariate_top_30 %	univariate	12	0.7941	0.7752	0.5503
univariate_top_20 %	univariate	8	0.7872	0.7686	0.5372
univariate_top_10 %	univariate	4	0.7452	0.7430	0.4860

V-B. Resultados de los Experimentos

La Tabla IV muestra los 8 esquemas evaluados, ordenados según la estrategia.

La Figura 1 ilustra la comparación entre experimentos: el número de features seleccionadas (panel izquierdo) y la evolución de AUC train vs AUC validación (panel derecho).

Experimentos de selección de variables – Sprint 2




Figura 1. Comparación de experimentos de selección de variables. Panel izquierdo: número de features por experimento (verde = ganador). Panel derecho: AUC train y AUC validación; la línea discontinua vertical marca el experimento `corr_le_0.85`.

V-C. Decisión Final: `corr_le_0.85`

El experimento `corr_le_0.85` fue adoptado como set final por ofrecer el mejor equilibrio entre:

- Desempeño de validación prácticamente equivalente al set `initial` (diferencia en AUC-val de solo **0.0018**).
- Reducción de 37 a **28 features**, eliminando colinealidad interna.
- Mayor parsimonia y mejor defendibilidad metodológica frente a un jurado.

Las 28 features seleccionadas cubren dimensiones operativas (`total_orders`, `delivered_orders`), temporales (`recency_days`, `customer_lifetime_days`), de cuotas y pago, logísticas, geográficas y de categoría de producto. Ninguna de las 13 variables excluidas por leakage figura en el set final.

VI. EVALUACIÓN VS. BASELINE DEL SPRINT 1

VI-A. Configuración de la Evaluación

La evaluación se realizó con el mismo script (`src/models/evaluate_model.py`), el mismo split temporal y el mismo umbral fijo $P80 = 197.01$ que los experimentos de selección, garantizando comparabilidad directa:

- Train: 83.589 clientes (`last_purchase < 2018-07-01`)
- Validation: 6.230 clientes (`last_purchase ≥ 2018-07-01`)
- Features: 28 (set `corr_le_0.85`)

VI-B. Métricas en Validación

La Tabla V compara las métricas del Sprint 2 contra el baseline logístico del Sprint 1.

Cuadro V
COMPARACIÓN DE MÉTRICAS: BASELINE SPRINT 1 VS SPRINT 2

Métrica	Baseline S1	Sprint 2 Val	Mejora
Precision	0.3000	0.4766	+58.9 %
Recall	0.1600	0.6294	+293.4 %
F1-Score	0.2100	0.5424	+158.3 %
ROC-AUC	0.5355	0.7929	+48.1 %
Gini	0.0710	0.5858	+724.4 %

La Figura 2 ilustra visualmente el contraste entre ambas versiones del modelo.




Figura 2. Comparación de métricas de clasificación entre el baseline de regresión logística del Sprint 1 y el modelo de Sprint 2 (`corr_le_0.85`, 28 features). Mejora sustancial en todas las métricas principales.

VI-C. Curva ROC y Coeficiente de Gini

La Figura 3 presenta la curva ROC del Sprint 2 junto a la curva aproximada del baseline del Sprint 1. El área bajo la curva sube de 0.5355 a **0.7929**, y el Gini de 0.071 a **0.586**, evidenciando que el enriquecimiento de variables y el control de leakage produjeron separabilidad real.

VI-D. Matriz de Confusión

Sobre el conjunto de validación (6.230 clientes), el modelo produce:

$$CM = \begin{pmatrix} TN = 3825 & FP = 983 \\ FN = 527 & TP = 895 \end{pmatrix} \quad (2)$$

El modelo identifica correctamente al **62.9 %** de los clientes premium (Recall) con una precisión del **47.7 %**. El Recall es el indicador más crítico en el contexto de negocio: detectar la mayor proporción posible del segmento de alto valor para orientar acciones de retención.




Figura 3. Curva ROC comparada entre el baseline del Sprint 1 (línea discontinua) y el modelo del Sprint 2 (línea continua). El área bajo la curva del Sprint 2 (AUC = 0.7929, Gini = 0.5858) supera ampliamente la diagonal aleatoria y el baseline previo (AUC = 0.5355).

VII. KPIs DE NEGOCIO Y DEFENSA DEL TARGET

VII-A. KPIs Observados

Los KPIs finales se calcularon sobre la master table limpia con el umbral fijo $dev = 197.01$. La Tabla VI resume los indicadores por segmento.

Cuadro VI
KPIs SEGMENTADOS — PREMIUM VS REGULAR

KPI	Premium	Regular
Cientes	19.220 (20.00 %)	76.876 (80.00 %)
Facturación total	BRL 8.088.732 (56.03 %)	BRL 6.348.316 (43.97 %)
Ticket promedio	BRL 402.66	BRL 92.27
Órdenes promedio	1.09	0.94
Lifetime promedio (días)	7.26	1.24
Máx. cuotas promedio	4.70	2.47
Uso de más de 1 cuota	71.55 %	42.60 %
Con entrega tardía	9.28 %	6.93 %
Recency promedio (días)	221.16	227.31

La Figura 4 ilustra la concentración de facturación y la diferencia de ticket promedio entre segmentos.




Figura 4. KPIs de negocio. Izquierda: concentración de facturación por segmento (el 20 % premium concentra el 56.03 % de la facturación). Derecha: ticket promedio por segmento (ratio 4.36x).

VII-B. Lectura de Negocio

Tres observaciones justifican la validez económica del segmento:

- El ratio **20 % / 56 %** indica que el target captura un segmento de valor real y no ruido estadístico.
- El ticket premium de BRL 402.66 es **4.36 veces** el ticket regular (BRL 92.27), coherente con la paradoja de compra única de alto valor documentada en el Sprint 1.
- El mayor lifetime (5.9x) y el mayor uso de cuotas (71.55 % vs 42.60 %) validan que las nuevas features del pipeline capturan patrones de comportamiento diferenciales reales del segmento premium.

VIII. VALIDACIÓN TEMPORAL CON HOLDOUT

El pipeline incluye un ciclo de simulación mensual sobre el periodo de holdout (agosto–octubre 2018, ventana temporal_2018q4), ejecutado con el umbral fijo calculado sobre *dev* mediante `--threshold-mode apply`. El objetivo es verificar que el umbral y las features generalizan a datos no vistos antes de pasar al Sprint 3.

La Tabla VII compara los KPIs principales entre el conjunto *dev* y el periodo de holdout.

Cuadro VII
COMPARACIÓN KPIs: DEV VS HOLDOUT (AGO–OCT 2018)

KPI	DEV	Holdout
Cientes activos	96.096	6.468
Cientes premium	19.220 (20.00 %)	1.253 (19.37 %)
Umbral aplicado	BRL 197.01 (fit)	BRL 197.01 (apply)
Ticket prem. / reg.	4.36x	4.47x

La tasa premium del holdout (19.37 %) y el ratio de ticket (4.47x) son consistentes con los valores del conjunto *dev*, lo que confirma dos propiedades del pipeline: (1) el umbral fijo no introduce sesgo temporal al aplicarse sobre una población distinta, y (2) las features del Sprint 2 capturan patrones de comportamiento estables entre periodos. La convergencia de ambas métricas valida la elección del P80 *dev* como referencia permanente para los sprints siguientes.

IX. CONCLUSIONES Y PRÓXIMOS PASOS

IX-A. Conclusiones

El Sprint 2 entregó los siguientes resultados verificables:

1. Un **pipeline modular y reproducible** en cuatro scripts independientes, con artefactos persistidos y numerados en `data/interim/` y `data/processed/`.
2. Un **target formalmente defendido**: P80 fijo sobre *dev* = BRL 197.01, con política de umbral `fit/apply` y exclusión documentada de cancelaciones.
3. **18 variables nuevas** que amplían el espacio de features más allá del RFM básico del Sprint 1.
4. Una **selección experimental** con 8 esquemas y el set óptimo de 28 features (`corr_le_0.85`), libre de las 13 variables excluidas por leakage.
5. **Mejora sustancial** en todas las métricas de clasificación: ROC-AUC 0.5355 $\rightarrow$ 0.7929 (+48.1 %), F1 0.21 $\rightarrow$ 0.54 (+158.3 %), Gini 0.071 $\rightarrow$ 0.586 (+724.4 %).

6. **KPIs económicamente sólidos:** 20 % premium, 56 % facturación, ticket 4.36× el regular.
7. **Validación con holdout:** simulación sobre agosto–octubre 2018 confirma tasa premium de 19.37 % y ratio de ticket de 4.47×, coherentes con *dev*, validando la estabilidad del umbral fijo y las features ante datos no vistos.

IX-B. Próximos Pasos — Sprint 3

Para el Sprint 3 se propone:

1. **Ventanas temporales:** separar la ventana de observación (construcción de features) de la ventana de outcome (etiquetado de *is_premium*) para una predicción verdaderamente prospectiva.
2. **Modelos de mayor capacidad:** evaluar Gradient Boosting y ensambles sobre las 28 features validadas.
3. **Análisis de valor económico:** estimar el CAC máximo recomendable por cliente premium a partir del ticket promedio y la tasa de retención estimada.
4. **Validación temporal adicional:** probar estabilidad de las features con splits de fechas distintos para confirmar robustez del pipeline.

REFERENCIAS

- [1] A. Ullah, M. I. Mohmand, H. Hussain, S. Johar, I. Khan, S. Ahmad, H. A. Mahmoud, and S. Huda, “Customer Analysis Using Machine Learning-Based Classification Algorithms for Effective Segmentation Using Recency, Frequency, Monetary, and Time,” *Sensors*, vol. 23, no. 6, p. 3180, Mar. 2023. [Online]. Available: <https://doi.org/10.3390/s23063180>
- [2] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, Oct. 2001. [Online]. Available: <https://doi.org/10.1023/A:1010933404324>
- [3] C. Genuer, J.-M. Poggi, and C. Tuleau-Malot, “Variable selection using random forests,” *Pattern Recognition Letters*, vol. 31, no. 14, pp. 2225–2236, Oct. 2010.

3. Sprint 3: Modelo Final y HPO

Reporte de Sprint 3: Hiperparametrización, Selección del Modelo Final y Exportación del Clasificador de Clientes Premium

Marcelo de la Quintana, Gaston Nina, y Gerick Toro
Módulo de Implementación de Soluciones de Inteligencia Artificial
Maestría en Inteligencia Artificial y Ciencia de Datos

Resumen—Este informe documenta el Sprint 3 del proyecto analítico sobre la plataforma Olist, cuyo objetivo fue seleccionar el algoritmo de clasificación de clientes premium con mayor capacidad predictiva y optimizar sus hiperparámetros para producir el artefacto de modelo serializado listo para producción. Partiendo de las 28 variables del experimento `corr_le_0.85` del Sprint 2 y del mismo split temporal (*train*: `last_purchase < 2018-07-01`; *validación*: `≥ 2018-07-01`), se evaluaron cinco modelos candidatos en configuración base: Regresión Logística, Random Forest, Gradient Boosting, XGBoost y LightGBM. El benchmark inicial confirmó a LightGBM ($\text{ROC-AUC}_{\text{val}} = 0.8035$, $\text{Gini}_{\text{val}} = 0.6070$) y XGBoost ($\text{ROC-AUC}_{\text{val}} = 0.7982$, $\text{Recall}_{\text{val}} = 0.6906$) como modelos finalistas mediante un ranking compuesto que pondera capacidad discriminante y cobertura del segmento premium. La optimización de hiperparámetros con Optuna TPE (50 *trials* por modelo) mejoró el ROC-AUC de LightGBM a 0.8081 (+0.0046) y el de XGBoost a 0.8070 (+0.0088). LightGBM se consolidó como modelo ganador por liderar en todas las métricas de discriminación global, con un gap de sobreajuste controlado de 0.039. El umbral óptimo de decisión (0.55) maximiza el F1-Score a 0.5603. Las variables `top_category` y `recency_days` concentran el 43 % de la importancia de ganancia del modelo. El pipeline serializado (`modelo_final.pkl`) supera en 1.52 puntos de ROC-AUC y 3.23 puntos de Recall al Random Forest del Sprint 2, estableciendo la base técnica para el despliegue en el Sprint 4.

Index Terms—LightGBM, XGBoost, Optuna, Hiperparametrización, Clasificación Supervisada, Clientes Premium, Olist, ROC-AUC, Gini, Feature Importance.

I. INTRODUCCIÓN

EL Sprint 2 entregó un pipeline reproducible de ingeniería de variables que elevó el ROC-AUC de clasificación de clientes premium de 0.5355 (baseline logístico del Sprint 1) a **0.7929** usando un Random Forest con 28 features del experimento `corr_le_0.85` [2]. Esa mejora confirmó que la **Paradoja del Target** [1] —donde el 97 % de los clientes de Olist tiene una única orden— puede ser abordada con variables de comportamiento de categoría de producto, logística y método de pago, más allá del esquema RFMT tradicional [3].

El **Sprint 3** tiene como objetivo responder: *¿qué algoritmo y con qué configuración de hiperparámetros maximiza la capacidad de identificar clientes premium sobre las 28 variables validadas?* Para ello se diseñó un flujo de cuatro etapas:

1. **S3-DS-01**: Benchmark inicial de cinco modelos candidatos en configuración base, con el mismo split temporal y features del Sprint 2.

2. **S3-DS-02**: Selección de modelos finalistas mediante criterio compuesto de métricas técnicas y contexto de negocio.
3. **S3-DS-03/04**: Optimización de hiperparámetros (HPO) de los finalistas con Optuna TPE, 50 *trials* por modelo.
4. **Evaluación y exportación**: Verificación de reproducibilidad del pipeline serializado.

La motivación de negocio permanece intacta desde el Sprint 1: el segmento premium (20 % de los clientes) concentra el **56.03 %** de la facturación de Olist, con un ticket promedio **4.36 veces** superior al del cliente regular (BRL 402.66 vs. BRL 92.27) [2]. En este contexto, **Recall es la métrica de negocio prioritaria**: un falso negativo implica perder la oportunidad de retención sobre el segmento de mayor valor.

II. CONFIGURACIÓN EXPERIMENTAL

II-A. Datos y Split Temporal

Se utilizó el dataset oficial de features del Sprint 2 (`06_features_selected.parquet`), con 96.096 clientes y 28 variables. Para aplicar el split temporal fue necesario combinar este archivo con `05_features_rfm.parquet` (fuente de `last_purchase`), ya que dicha columna fue excluida del set de features por ser información temporal que no estaría disponible en producción.

Cuadro I
PARTICIÓN DE DATOS — SPRINT 3

Conjunto	Criterio	Registros
Train	<code>last_purchase < 2018-07-01</code>	83.589
Validación	<code>last_purchase ≥ 2018-07-01</code>	6.230
Tasa premium en train		21.29 %
Tasa premium en validación		22.83 %

II-B. Preprocesamiento

Todos los modelos comparten el mismo preprocesador encapsulado en un `ColumnTransformer` de `scikit-learn`:

- **Variables numéricas (22)**: imputación por mediana (`SimpleImputer`).
- **Variables categóricas (6)**: imputación por moda + codificación `OneHotEncoder` con `handle_unknown='ignore'`.

El preprocesador se ajusta (*fit*) exclusivamente sobre el conjunto de train y se aplica (*transform*) sobre validación, garantizando la ausencia de fuga de información en la normalización.

II-C. Desbalance de Clases

La proporción de clientes regulares frente a premium en train es aproximadamente 3.70:1. Para compensar este desbalance sin submuestreo (lo que preserva toda la información de entrenamiento), cada modelo recibe la corrección apropiada:

- `class_weight='balanced'`: Regresión Logística, LightGBM.
- `class_weight='balanced_subsample'`: Random Forest.
- `scale_pos_weight=3.70`: XGBoost.
- Sin ajuste explícito: Gradient Boosting (sklearn), que por diseño es menos sensible al desbalance en su implementación interna.

III. S3-DS-01: BENCHMARK DE MODELOS CANDIDATOS

III-A. Modelos Evaluados

La Tabla II describe los cinco modelos candidatos con su configuración base.

Cuadro II
MODELOS CANDIDATOS — CONFIGURACIÓN BASE

Modelo	Tipo	Configuración base
logistic_regression	Lineal	<code>class_weight='balanced'</code> , scaler
random_forest	Bagging	200 árboles, <code>balanced_subsample</code>
gradient_boosting	Boosting sklearn	200 estimadores, <code>lr=0.05</code>
xgboost	Boosting XGB	250 estim., <code>scale_pos_weight=3.70</code>
lightgbm	Boosting LGBM	250 estim., <code>class_weight='balanced'</code>

III-B. Resultados del Benchmark

La Tabla III presenta las métricas de validación de los cinco modelos, ordenadas por ROC-AUC descendente. La columna *Gap* representa la diferencia entre ROC-AUC en train y en validación, como indicador de sobreajuste.

Cuadro III
BENCHMARK INICIAL — MÉTRICAS EN VALIDACIÓN

Modelo	AUC val	Gini val	PR-AUC	F1 val	Recall val	Gap
lightgbm	0.8035	0.6070	0.5954	0.5565	0.6653	0.037
gradient_boosting	0.7985	0.5970	0.5881	0.4524	0.3340	0.027
xgboost	0.7982	0.5964	0.5896	0.5504	0.6906	0.029
random_forest	0.7926	0.5852	0.5677	0.5422	0.6392	0.019
logistic_regression	0.7884	0.5768	0.5661	0.5329	0.6456	0.016

La Figura 1 ilustra visualmente la comparación entre ROC-AUC de train y validación para los cinco modelos.

III-C. Continuidad con el Sprint 2

El resultado de `random_forest` en validación (ROC-AUC = 0.7926) es prácticamente idéntico al resultado oficial del Sprint 2 (`corr_le_0.85`, ROC-AUC = 0.7929). Esta diferencia de 0.0003 confirma la reproducibilidad del pipeline y que el benchmark parte de una base estable.




Figura 1. Comparación de ROC-AUC train vs. validación para los cinco modelos candidatos. El gap moderado de LightGBM (0.037) y XGBoost (0.029) es aceptable para la fase de tuning.

Los modelos de boosting mejoran el baseline del Sprint 2 entre +0.6 y +1.1 puntos de ROC-AUC, validando la hipótesis de que algoritmos de mayor capacidad no lineal capturan mejor los patrones de la Paradoja del Target.

IV. S3-DS-02: SELECCIÓN DE MODELOS FINALISTAS

IV-A. Criterios de Selección

La selección de finalistas aplicó cuatro criterios combinados. Los umbrales mínimos de AUC y Gini garantizan mejora real sobre el Sprint 2; el límite de gap controla el riesgo de sobreajuste en producción.

Cuadro IV
CRITERIOS DE SELECCIÓN DE FINALISTAS

Criterio	Umbral	Justificación
ROC-AUC val	$\geq 0,78$	Mejora sobre baseline S2
Gini val	$\geq 0,56$	Equivalente a $AUC \geq 0,78$
Gap overfit	$\leq 0,06$	Estabilidad aceptable
Ranking compuesto	Top 2	$0,5 \times AUC + 0,3 \times Gini + 0,2 \times F1$

El ranking compuesto incorpora F1 para penalizar modelos con Recall bajo. Esta decisión fue determinante: `gradient_boosting` supera a XGBoost en ROC-AUC por 0.0003 (0.7985 vs. 0.7982), pero su Recall de **0.33** significaría dejar sin detectar al 67 % de los clientes premium, perdiendo el acceso al segmento responsable del 56 % de la facturación. El ranking compuesto selecciona correctamente a XGBoost sobre Gradient Boosting gracias al componente F1 (0.5504 vs. 0.4524).

IV-B. Finalistas Seleccionados

Los modelos finalistas son **LightGBM** y **XGBoost**, con los argumentos técnicos resumidos en la Tabla V.

V. S3-DS-03/04: OPTIMIZACIÓN DE HIPERPARÁMETROS

V-A. Metodología: Optuna TPE

La optimización de hiperparámetros (HPO) se realizó con **Optuna** [4] usando el método de muestreo **TPE** (Tree-structured Parzen Estimator). A diferencia de la búsqueda por

Cuadro V
ARGUMENTOS TÉCNICOS POR FINALISTA

Argumento	LightGBM	XGBoost
ROC-AUC val	0.8035	0.7982
Gini val	0.6070	0.5964
Recall val	0.6653	0.6906
F1 val	0.5565	0.5504
Gap overfit	0.037	0.029
Fortaleza	Discriminación global	Mayor Recall base

grilla (GridSearchCV), TPE construye un modelo probabilístico del espacio de hiperparámetros basado en los *trials* anteriores, dirigiendo la búsqueda hacia las regiones con mayor probabilidad de mejora. Esta estrategia bayesiana es significativamente más eficiente que GridSearch en espacios continuos de alta dimensión [5].

Configuración: 50 *trials* por modelo; objetivo de maximización: ROC-AUC en validación; semilla fija para reproducibilidad (*seed*=42).

V-B. Espacio de Búsqueda — LightGBM

La Tabla VI resume el espacio de hiperparámetros explorado para LightGBM.

Cuadro VI
ESPACIO DE BÚSQUEDA HPO — LIGHTGBM

Hiperparámetro	Rango	Escala
num_leaves	[20, 150]	Entero
max_depth	[3, 10]	Entero
learning_rate	[0.01, 0.20]	Log-uniforme
n_estimators	[100, 500]	Entero
min_child_samples	[10, 100]	Entero
subsample	[0.6, 1.0]	Uniforme
colsample_bytree	[0.6, 1.0]	Uniforme
reg_alpha	[10 ⁻⁸ , 1.0]	Log-uniforme
reg_lambda	[10 ⁻⁸ , 1.0]	Log-uniforme

XGBoost exploró un espacio equivalente con sus parámetros nativos (*max_depth*, *min_child_weight*, *gamma*, *reg_alpha*, *reg_lambda*).

La Figura 2 muestra la evolución del ROC-AUC a lo largo de los 50 *trials* para cada modelo, donde se aprecia la convergencia progresiva del mejor valor acumulado.

V-C. Hiperparámetros Óptimos — LightGBM (Ganador)

$$\theta^* = \{n_l=59, d=8, \eta=0.054, T=255, m=68, s=0.906, c=0.865\} \quad (1)$$

donde n_l = num_leaves, d = max_depth, η = learning_rate, T = n_estimators, m = min_child_samples, s = subsample, c = colsample_bytree.




Figura 2. Historia de optimización Optuna TPE (50 *trials* por modelo). Cada punto representa un *trial* individual; la línea continua muestra el mejor valor acumulado. Ambos modelos convergen tras aproximadamente 30 *trials*.

V-D. Resultados del Tuning

La Tabla VII compara las métricas baseline y post-tuning de ambos finalistas.

Cuadro VII
RESULTADOS DE HPO: BASELINE VS. TUNEADO

Modelo	AUC val	Gini val	PR-AUC	F1 val	Recall val	Gap
LGBM baseline	0.8035	0.6070	0.5954	0.5565	0.6653	0.037
LGBM tuneado	0.8081	0.6162	0.6010	0.5576	0.6617	0.039
XGB baseline	0.7982	0.5964	0.5896	0.5504	0.6906	0.029
XGB tuneado	0.8070	0.6140	0.5997	0.5560	0.6505	0.054

La Figura 3 ilustra el delta de mejora entre baseline y tuneado para las tres métricas principales.




Figura 3. Comparación de métricas baseline vs. tuneado para LightGBM y XGBoost. El tuning de XGBoost logra la mayor ganancia en ROC-AUC (+0.0088), pero a costa de reducir el Recall de 0.6906 a 0.6505.

Observación sobre XGBoost tuneado: La optimización elevó el ROC-AUC de XGBoost en +0.0088, la mayor ganancia absoluta entre ambos modelos. Sin embargo, el Recall descendió de 0.6906 a 0.6505, ya que Optuna maximizó ROC-AUC y no Recall directamente. Si el objetivo de negocio fuera maximizar la cobertura del segmento premium, una corrida adicional de HPO con Recall como función objetivo podría revertir este trade-off. Para el presente sprint, la selección del ganador prioriza las métricas de discriminación global.

VI. MODELO FINAL: LIGHTGBM TUNEADO

VI-A. Justificación de la Selección

LightGBM tuneado es seleccionado como modelo de producción por cuatro razones:

- Mayor ROC-AUC y Gini:** 0.8081 y 0.6162, liderando en discriminación global.
- Gap de sobreajuste controlado:** 0.039, inferior al umbral crítico de 0.06 definido en los criterios de selección.

3. **Velocidad de entrenamiento:** LightGBM es significativamente más rápido que XGBoost en datasets de más de 50.000 filas, lo que facilita las iteraciones de reentrenamiento mensual del Sprint 4.
4. **Feature importance nativa:** la ganancia por característica es directamente interpretable y comparable entre modelos, facilitando la comunicación con el equipo de negocio.

VI-B. Métricas en Validación

La Tabla VIII presenta las métricas del modelo final bajo dos umbrales de decisión.

Cuadro VIII
MÉTRICAS DEL MODELO FINAL — LIGHTGBM TUNEADO

Métrica	Umbral 0.50	Umbral 0.55
ROC-AUC	0.8081	
Gini	0.6162	
PR-AUC	0.6010	
Precision	0.4818	0.5225
Recall	0.6617	0.6041
F1-Score	0.5576	0.5603
Gap overfit	0.039	

VI-C. Análisis del Umbral de Decisión

El umbral de decisión controla el trade-off entre Precision y Recall. El umbral por defecto de scikit-learn es 0.50, pero el umbral que maximiza el F1-Score sobre el conjunto de validación es **0.55**, que reduce levemente el Recall ($0.4818 \rightarrow 0.6041$) a cambio de elevar la Precision ($0.4818 \rightarrow 0.5225$), mejorando el F1 en 0.0027 puntos.

La Figura 4 ilustra la evolución de las tres métricas en función del umbral de clasificación.




Figura 4. Evolución de Precision, Recall y F1 en función del umbral de decisión. El umbral óptimo (0.55, línea discontinua gris) maximiza el F1-Score. El umbral por defecto (0.50, línea naranja punteada) favorece el Recall.

La elección final del umbral de producción es una decisión de negocio. Para el Sprint 4, se recomienda:

- **Umbral 0.50:** si la prioridad es maximizar la cobertura del segmento premium (Recall = 0.66).
- **Umbral 0.55:** si se busca el mejor equilibrio F1 (Recall = 0.60, Precision = 0.52).

VI-D. Matriz de Confusión

Sobre los 6.230 clientes de validación (1.422 premium reales), la Tabla IX presenta la matriz de confusión con el umbral óptimo 0.55.

Cuadro IX
MATRIZ DE CONFUSIÓN — LIGHTGBM TUNEADO (UMBRAL = 0.55)

		Predicción	
		Regular (0)	Premium (1)
Real	Regular (0)	TN = 4.023	FP = 785
	Premium (1)	FN = 563	TP = 859

El modelo detecta correctamente a **859 de 1.422 clientes premium** (Recall = 60.4 %). Los 563 falsos negativos representan clientes de alto valor no identificados; los 785 falsos positivos son clientes regulares clasificados erróneamente como premium.

La Figura 5 compara las matrices bajo ambos umbrales.




Figura 5. Matrices de confusión del modelo final para los umbrales 0.50 (izquierda) y 0.55 (derecha). El umbral 0.55 reduce los falsos positivos a cambio de un leve aumento en los falsos negativos.

VI-E. Curvas ROC y Precision-Recall

La Figura 6 presenta las curvas ROC y Precision-Recall del modelo final junto a las referencias de clasificación aleatoria.




Figura 6. Curvas ROC (izquierda) y Precision-Recall (derecha) del modelo ganador. El AUC-ROC de 0.8081 representa una ganancia de +1.52 puntos sobre el Random Forest del Sprint 2 (0.7929). El PR-AUC de 0.6010 supera significativamente la línea base aleatoria (0.23).

VII. INTERPRETACIÓN DE VARIABLES (FEATURE IMPORTANCE)

VII-A. Metodología

La importancia de variables se calculó mediante la **ganancia media por característica** en los árboles del modelo tuneado (gain-based importance), que mide cuánto reduce el error de clasificación cada variable al ser usada como criterio de división. Este análisis fue desarrollado en el notebook `03_interpretacion_feature_audit.ipynb` por el equipo de ingeniería de datos.

VII-B. Top 10 Variables — LightGBM Tuneado

La Tabla X presenta las diez variables de mayor importancia y su interpretación de negocio.

Cuadro X
TOP 10 VARIABLES POR IMPORTANCIA DE GANANCIA — LIGHTGBM TUNEADO

#	Variable	Importancia	Dominio
1	top_category	21.98 %	Producto
2	recency_days	21.02 %	Temporal
3	avg_estimated_delivery_days	10.62 %	Logística
4	avg_delivery_days	8.53 %	Logística
5	delivery_gap	6.73 %	Derivada
6	max_payment_installments	6.64 %	Pagos
7	customer_state	4.16 %	Geografía
8	total_items	4.12 %	Transaccional
9	avg_review_score	2.64 %	Reseñas
10	region_group	2.24 %	Geografía

VII-C. Lectura de Negocio de las Variables Líderes

Las dos variables más importantes concentran el **43 %** de la ganancia total del modelo:

top_category (21.98 %): La categoría de producto más comprada por el cliente es el predictor más fuerte del segmento premium. Los clientes que adquieren productos de categorías de alto valor (electrónica, relojes, instrumentos musicales, muebles de oficina) generan tickets muy superiores en una única transacción. Esta variable captura directamente la Paradoja del Target: no es la frecuencia de compra, sino el *tipo* de compra lo que define al cliente premium.

recency_days (21.02 %): La recencia —días transcurridos desde la última compra hasta el corte temporal— tiene alta importancia porque los clientes premium de Olist tienden a ser compradores recientes con pedidos de mayor valor. Los compradores con alta antigüedad pero bajo gasto acumulado son típicamente clientes con múltiples órdenes de bajo valor, no el perfil premium.

Las variables logísticas (`avg_delivery_days`, `delivery_gap`) reflejan que los productos de categorías premium suelen tener mayor complejidad de envío, confirmando la correlación entre comportamiento logístico y valor del cliente.

La Figura 7 muestra el ranking completo de las 20 variables más importantes para LightGBM y XGBoost.




Figura 7. Top 20 variables por importancia de ganancia para LightGBM (izquierda) y XGBoost (derecha) en sus versiones tuneadas. Ambos modelos coinciden en las variables líderes (`top_category`, `recency_days`), validando la consistencia del análisis.

VIII. SERIALIZACIÓN Y VERIFICACIÓN DE REPRODUCIBILIDAD

VIII-A. Pipeline de Producción

El modelo final se exporta como un `Pipeline` de scikit-learn que encapsula el preprocesador y el clasificador en un único artefacto:

```
pipeline = [ColumnTransformer → LGBMClassifier( $\theta^*$ )]
```

(2)

Este diseño garantiza que en producción se aplique exactamente el mismo preprocesamiento utilizado en entrenamiento, eliminando el riesgo de inconsistencias por transformaciones omitidas o aplicadas en distinto orden.

VIII-B. Verificación Round-Trip

El notebook `04_evaluacion_modelo_final.ipynb` reconstruye el pipeline desde `10_tuning_results.json`, lo entrena sobre el conjunto de desarrollo y verifica que el modelo serializado (`modelo_final.pkl`) produce predicciones idénticas al pipeline en memoria, con una diferencia en ROC-AUC inferior a 10^{-8} .

VIII-C. Comparación con Sprints Anteriores

La Tabla XI resume la evolución del rendimiento a lo largo de los tres sprints.

Cuadro XI
EVOLUCIÓN DE MÉTRICAS POR SPRINT

Sprint	Modelo	ROC-AUC	Recall	F1
S1 (baseline)	Logística (RFMT básico)	0.5355	0.16	0.21
S2 (pipeline)	Random Forest, 28 feat.	0.7929	0.63	0.54
S3 (final)	LightGBM tuneado	0.8081	0.66	0.56
Mejora S1 → S3		+50.8 %	+312.5 %	+166.7 %
Mejora S2 → S3		+1.9 %	+4.9 %	+3.7 %

IX. CONCLUSIONES Y PRÓXIMOS PASOS

IX-A. Conclusiones

El Sprint 3 entregó los siguientes resultados verificables:

- Benchmark comparativo** de cinco modelos sobre el set oficial de 28 features y split temporal del Sprint 2,

- con métricas completas (ROC-AUC, Gini, PR-AUC, F1, Precision, Recall, gap de sobreajuste).
2. **Selección justificada** de LightGBM y XGBoost como finalistas mediante ranking compuesto, evitando la trampa de ordenar únicamente por ROC-AUC que habría seleccionado a Gradient Boosting con Recall inaceptable (0.33).
 3. **HPO con Optuna TPE** (50 trials por modelo): LightGBM mejoró +0.0046 en ROC-AUC; XGBoost mejoró +0.0088 en ROC-AUC pero redujo su Recall en 4 puntos al optimizar para AUC.
 4. **Modelo final** LightGBM tuneado: ROC-AUC = 0.8081, Gini = 0.6162, Recall = 0.6617 (umbral 0.50), con umbral óptimo F1 en 0.55.
 5. **Interpretabilidad:** `top_category` y `recency_days` explican el 43 % de la ganancia del modelo, confirmando que el tipo de producto y la temporalidad de la compra son los mejores discriminadores del segmento premium en el contexto de la Paradoja del Target.
 6. **Artefacto serializado** (`modelo_final.pkl`): pipeline reproducible verificado con $\Delta \text{ROC-AUC} < 10^{-8}$ en la verificación round-trip.

- [4] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," in *Proc. ACM KDD*, 2019. [Online]. Available: <https://doi.org/10.1145/3292500.3330701>
- [5] J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, "Algorithms for Hyperparameter Optimization," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 24, 2011.
- [6] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.
- [7] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proc. ACM KDD*, pp. 785–794, 2016. [Online]. Available: <https://doi.org/10.1145/2939672.2939785>

IX-B. Próximos Pasos — Sprint 4

Para el Sprint 4 se propone:

1. **API de scoring (FastAPI):** Endpoint REST que recibe las 28 features de un cliente y retorna `is_premium` con la probabilidad asociada, usando `modelo_final.pkl`.
2. **Dashboard (Streamlit):** Visualización del segmento premium identificado, KPIs de negocio actualizados y distribución de scores por estado geográfico.
3. **Gobernanza y ética:** Análisis de equidad del clasificador por `customer_state` y `region_group` (las variables geográficas tienen 6.4 % de importancia combinada), para detectar posibles sesgos de cobertura por región.
4. **Reentrenamiento mensual:** Script orquestador que ejecuta el pipeline completo —desde la master table hasta la exportación de un nuevo `.pkl`— sobre datos actualizados, manteniendo el umbral P80 en modo apply.
5. **HPO orientado a Recall:** Explorar una corrida adicional de Optuna con Recall como función objetivo para XGBoost, dado el trade-off observado en este sprint.

REFERENCIAS

- [1] M. de la Quintana, G. Nina, y G. Toro, "Reporte de Sprint 1: Perfilado de Datos Crudos, Exploración y Modelo Baseline para la Identificación de Clientes Premium," *Informe Técnico, Módulo de Implementación de Soluciones de IA, Maestría en IA y Ciencia de Datos*, mayo 2026.
- [2] M. de la Quintana, G. Nina, y G. Toro, "Reporte de Sprint 2: Pipeline Reproducible de Ingeniería de Variables y Clasificación de Clientes Premium," *Informe Técnico, Módulo de Implementación de Soluciones de IA, Maestría en IA y Ciencia de Datos*, junio 2026.
- [3] A. Ullah, M. I. Mohmand, H. Hussain, S. Johar, I. Khan, S. Ahmad, H. A. Mahmoud, and S. Huda, "Customer Analysis Using Machine Learning-Based Classification Algorithms for Effective Segmentation Using Recency, Frequency, Monetary, and Time," *Sensors*, vol. 23, no. 6, p. 3180, Mar. 2023. [Online]. Available: <https://doi.org/10.3390/s23063180>

4. Sprint 4: MVP, Backtest y Gobernanza

Reporte de Sprint 4: Integración del MVP, Validación Backtest, Explicabilidad SHAP y Storytelling de Negocio

Marcelo de la Quintana, Gaston Nina, y Gerick Toro
Módulo de Implementación de Soluciones de Inteligencia Artificial
Maestría en Inteligencia Artificial y Ciencia de Datos

Resumen—Este informe documenta el Sprint 4 del proyecto de identificación de clientes premium sobre Olist, cuyo objetivo fue transformar el modelo final del Sprint 3 en un MVP defendible para Demo Day, integrando un pipeline reproducible de scoring sobre una ventana de backtest, un dashboard en Streamlit, una API mínima, explicabilidad local y global, y una narrativa de impacto de negocio. El pipeline reutilizado genera `backtest_features_selected.parquet` alineado al esquema esperado por `modelo_final.pkl`. Sobre el backtest de agosto de 2018 se obtuvo un ROC-AUC de 0.9876, Gini de 0.9751, Precision de 43.80 %, Recall de 56.11 % y F1-Score de 49.20 %. Sin embargo, se argumenta que este desempeño no debe interpretarse de forma aislada como evidencia absoluta de generalización superior, ya que la etiqueta premium se define por gasto acumulado y el backtest presenta una población mucho más desbalanceada y estructuralmente más fácil que la validación de Sprint 3. A nivel de negocio, el modelo permite pasar de una campaña masiva con ROI estimado de -89.57 % a una campaña focalizada con ROI de +250.40 %, reduciendo el costo comercial en BRL 1,417,365.00. La explicabilidad se reforzó con contribuciones locales nativas de LightGBM y un SHAP Summary Plot tipo beeswarm, mientras que la capa de gobernanza quedó documentada en términos de sesgo logístico, señales de pago y supervisión humana.

Index Terms—Streamlit, FastAPI, Docker, Backtest Temporal, SHAP, LightGBM, Clasificación Supervisada, Clientes Premium, Olist, ROI, Gobernanza de Modelos.

I. INTRODUCCIÓN

EL Sprint 3 cerró con un modelo LightGBM tuneado serializado como `modelo_final.pkl`, seleccionado por maximizar la discriminación global sobre el split temporal de desarrollo y validación ($\text{last_purchase} < / \geq 2018-07-01$), alcanzando $\text{ROC-AUC}_{\text{val}} = 0.8081$ y $\text{Gini}_{\text{val}} = 0.6162$. El objetivo del **Sprint 4** fue convertir ese artefacto analítico en una demostración funcional y defendible para negocio, preservando reproducibilidad, explicabilidad y trazabilidad.

El sprint se organizó en cuatro bloques:

1. Reutilización del pipeline para generar un dataset de scoring en backtest.
2. Construcción del MVP en Streamlit y empaquetado reproducible en Docker.
3. Validación analítica sobre backtest con métricas técnicas, explicabilidad y simulación financiera.
4. Consolidación de narrativa ejecutiva, gobernanza y checklist de Demo Day.

La pregunta central del Sprint 4 ya no es “¿qué modelo rinde mejor?”, sino *¿podemos demostrar que el modelo final es integrable, explicable y útil para una decisión comercial realista?*

I-A. Angulo correcto de defensa

Para exposición académica y ejecutiva conviene fijar una distinción explícita: **Sprint 3** es la validación metodológica principal del clasificador, mientras que **Sprint 4** es la validación de producto mínimo viable. Por ello, el resultado más importante del sprint no es “mejorar” artificialmente el AUC, sino demostrar cinco capacidades concretas:

1. scoring reproducible sobre una ventana de backtest;
2. integración funcional en dashboard y API;
3. explicabilidad local y global con SHAP;
4. traducción del score a impacto económico mediante ROI;
5. documentación de riesgos, gobernanza y límites metodológicos.

II. ARQUITECTURA DEL SPRINT 4

II-A. Flujo técnico

El flujo implementado sigue la secuencia:

`backtest` → `master_table_backtest`
→ `backtest_features_rfm` → `backtest_features_selected`




Figura 1. Arquitectura final del MVP de Sprint 4. El pipeline prepara el dataset de scoring, mientras dashboard y API consumen el mismo artefacto del modelo dentro de contenedores separados.

Los entregables principales del sprint son:

- `backtest_features_selected.parquet` y `demo_sample_scoring.parquet` en `data/processed/`.
- `app.py` del dashboard en `app/dashboard/`.
- `main.py` de la API en `app/api/`.
- Figuras principales del sprint en `reports/figures/`, incluyendo ROI y SHAP beeswarm.

II-B. Compatibilidad operativa

Tras regenerar el artefacto `modelo_final.pkl` en un entorno actualizado, los contenedores del dashboard y la API se fijaron en Python 3.12. La validación realizada en Sprint 4 comprobó que el modelo se carga correctamente dentro de ambos contenedores Docker y mantiene compatibilidad operativa con el MVP.

III. VALIDACIÓN BACKTEST

III-A. Definición del escenario backtest

Aunque el split técnico histórico del proyecto conservó una partición `holdout_3m` entre agosto y octubre de 2018, la distribución real de órdenes mostró que septiembre y octubre están prácticamente vacíos. Para evitar una evaluación final apoyada en una cola truncada, Sprint 4 formaliza como backtest la ventana completa de **agosto de 2018** (backtest) y aplica el mismo umbral de negocio persistido en desarrollo: un cliente es premium si su gasto acumulado en la ventana es mayor o igual al umbral fijo de BRL **197.01** (P80 del conjunto de desarrollo).

Cuadro I
RESUMEN DEL BACKTEST SPRINT 4

Métrica	Valor
Cientes evaluados	96,096
Cientes premium reales	1,253
Tasa premium real	1.30 %
Cientes predichos como premium	1,605
Tasa premium predicha	1.67 %
Umbral de clasificación	0.55

III-B. Métricas técnicas

Cuadro II
MÉTRICAS TÉCNICAS SOBRE BACKTEST

Métrica	Valor
ROC-AUC	0.9876
Gini	0.9751
Precision	43.80 %
Recall	56.11 %
F1-Score	49.20 %

III-C. Interpretación crítica del ROC-AUC alto

Aunque el ROC-AUC de **0.9876** es notablemente superior al ROC-AUC de validación del Sprint 3 (**0.8081**), esta diferencia no debe interpretarse automáticamente como una mejora masiva de generalización del modelo. Tampoco es evidencia directa de sobreajuste clásico, ya que el overfitting se manifiesta cuando el rendimiento en datos no vistos cae respecto al desarrollo, no cuando aumenta.

La explicación más plausible combina dos factores metodológicos:

1. **La tarea en backtest es más fácil.** La población evaluada contiene una gran masa de clientes sin actividad o con actividad mínima en la ventana, mientras que el segmento premium exige al menos gasto suficiente para superar el umbral fijo. Esta separación estructural facilita la discriminación.
2. **La etiqueta premium está muy acoplada a señales transaccionales.** Aunque se excluyeron variables de leakage directo como `total_spent` y `avg_ticket`, se conservaron proxies fuertes del comportamiento de gasto, como `delivered_orders`, `total_items`, `max_payment_installments` y `top_category_is_high_value`. Por ello, el modelo no memoriza el target, pero sí resuelve una tarea muy cercana al criterio de negocio que define la etiqueta.

III-D. Nota sobre el holdout historico de 3 meses

El split `holdout_3m` se mantiene en el repositorio por compatibilidad y trazabilidad del trabajo previo, pero no se usa ya como escenario oficial de evaluación final del Sprint 4. La razón es que septiembre y octubre de 2018 solo aportan 20 órdenes combinadas, por lo que no constituyen una ventana seria para juzgar desempeño. En consecuencia:

- no interpretamos septiembre y octubre como evidencia de tendencia comercial;
- no usamos esa cola para sostener métricas finales del modelo;
- tratamos agosto de 2018 como backtest oficial y dejamos el holdout de tres meses como antecedente del recorte temporal.

En consecuencia, para defensa académica se recomienda presentar este AUC como **evidencia de fuerte separabilidad del escenario backtest**, no como prueba única de superioridad absoluta del modelo. La comparación metodológicamente correcta del modelo sigue siendo la validación temporal del Sprint 3.

IV. EXPLICABILIDAD

IV-A. SHAP local y global

La demo incorpora explicabilidad local por cliente mediante `pred_contrib=True` de LightGBM sobre el espacio transformado por el ColumnTransformer. Adicionalmente, se generó un SHAP Summary Plot tipo beeswarm sobre una muestra del backtest.

Las variables líderes del SHAP global son coherentes con la lógica del caso:




Figura 2. SHAP Summary Plot (beeswarm) sobre una muestra de 3,000 clientes del backtest. Las variables más influyentes son predominantemente transaccionales y de valor comercial.

- delivered_orders
- max_payment_installments
- total_items
- top_category_is_high_value

Esto refuerza la interpretación de que el modelo identifica intensidad transaccional, participación en categorías de alto valor y comportamiento de pago como señales dominantes del segmento premium.

V. IMPACTO DE NEGOCIO

V-A. Simulación financiera

Se compararon dos estrategias:

1. **Campaña masiva:** contactar a toda la base.
2. **Campaña focalizada:** contactar solo a clientes con probabilidad $\geq 0,55$.

Cuadro III
COMPARATIVA DE ESTRATEGIAS COMERCIALES

Métrica	Masiva	Modelo
Clientes contactados	96,096	1,605
Costo de campaña	BRL 1,441,440.00	BRL 24,075.00
Ingreso por conversiones	BRL 150,360.00	BRL 84,360.00
Utilidad neta	BRL -1,291,080.00	BRL 60,285.00
ROI	-89.57 %	+250.40 %




Figura 3. Matriz de confusión sobre backtest y comparativa de ROI entre campaña masiva y campaña optimizada por modelo.

VI. MONITOREO OPERATIVO Y CRITERIO DE REENTRENAMIENTO

El MVP de Sprint 4 no debe interpretarse como un artefacto estático válido para cualquier momento futuro. Dado que el modelo fue entrenado sobre comportamiento histórico, su utilidad depende de que la relación entre señales transaccionales, contexto logístico y definición de cliente premium se mantenga razonablemente estable en el tiempo.

VI-A. Qué debe monitorearse

En una operación posterior al Demo Day, el dashboard o una capa de monitoreo debería revisar al menos cuatro grupos de señales:

- **Desempeño discriminativo:** métricas como ROC-AUC, Gini, Precision y Recall sobre ventanas nuevas no usadas en entrenamiento.
- **Impacto comercial:** ROI observado o estimado de la campaña focalizada frente a una estrategia masiva o baseline operativo.
- **Estabilidad poblacional:** tasa predicha de clientes premium y volumen de clientes efectivamente priorizados.
- **Drift de variables clave:** cambios relevantes en delivered_orders, total_items, max_payment_installments, customer_state o top_category_is_high_value.

VI-B. Cuándo revisar o reentrenar

La recomendación metodológica es **no reentrenar por calendario fijo**, sino por evidencia de deterioro sostenido. Como criterio operativo inicial para el MVP, puede proponerse:

- **Alerta amarilla:** caída de Gini superior al 20 % respecto al baseline de referencia o descenso consistente de precision comercial.
- **Alerta roja:** Gini por debajo de un umbral mínimo acordado con negocio, acompañado por deterioro del ROI o por un cambio brusco en la tasa premium predicha.
- **Revisión obligatoria:** drift simultáneo en varias variables dominantes del modelo, aun si la métrica agregada todavía luce aceptable.

VI-C. Base temporal correcta para reentrenar

Si se confirma degradación, el nuevo entrenamiento debe construirse sobre una **ventana temporal más reciente y completa**, separada del período usado por el artefacto vigente. Esta distinción es importante: mostrar resultados mes a mes sobre historia ya vista por el modelo puede servir como backtesting descriptivo del negocio, pero no como prueba suficiente de vigencia futura. En consecuencia, el reentrenamiento debe apoyarse en datos nuevos y comparables, no solo en recombinar la misma historia conocida.

VII. GOBERNANZA Y RIESGOS

El Sprint 4 también consolidó una lectura de riesgo para uso responsable del MVP:

- **Sesgo logístico/geográfico:** variables de tiempos de entrega y estimación pueden capturar desigualdades regionales.
- **Sesgo por bancarización:** señales como cuotas y método de pago pueden favorecer perfiles con mayor acceso financiero.
- **Necesidad de supervisión humana:** el score se propone como apoyo a priorización comercial, no como criterio automático único.

VIII. CONCLUSIONES

El Sprint 4 logró cerrar el ciclo de integración entre analítica y producto:

1. Se reutilizó el pipeline para construir un dataset de backtest alineado al artefacto oficial.
2. Se implementó un MVP en Streamlit y una API mínima reproducibles en Docker.
3. Se validó el modelo sobre backtest con métricas técnicas, explicabilidad y simulación de impacto.
4. Se documentaron riesgos éticos, pitch ejecutivo y checklist final de cierre.

La principal advertencia metodológica del sprint es que el backtest presenta un escenario más separable que la validación del Sprint 3. Por ello, el ROC-AUC de 0.9876 debe defenderse como resultado de un problema más fácil y de una etiqueta fuertemente ligada al comportamiento transaccional, no como una prueba aislada de superioridad definitiva del modelo.

REFERENCIAS

- [1] M. de la Quintana, G. Nina, y G. Toro, "Reporte de Sprint 3: Hiperparametrización, Selección del Modelo Final y Exportación del Clasificador de Clientes Premium," *Informe Técnico, Módulo de Implementación de Soluciones de IA, Maestría en IA y Ciencia de Datos*, junio 2026.
- [2] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.