

Universidad Mayor de San Andres

Maestria en Inteligencia Artificial y Ciencia de Datos

Reporte Final Unificado Extendido

Segmentacion Predictiva de Clientes Premium en Olist

Modulo de Implementacion de Soluciones de Inteligencia Artificial

Marcelo de la Quintana

Gaston Nina

Gerick Toro

Junio 2026

Índice

1. Resumen Ejecutivo	2
2. Introduccion	2
3. Problema de Negocio y Objetivo Analitico	3
4. Datos y Perfilado de Calidad	3
4.1. Valores faltantes e inconsistencias	3
4.2. Asimetria monetaria y cola larga	4
4.3. La paradoja del target	4
5. Definicion del Target Premium	5
6. Validacion del Segmento desde Negocio	5
7. Arquitectura del Pipeline Reproducible	6
8. Ingenieria de Variables	6
9. Seleccion Experimental de Variables	7
10. Baseline y Mejora del Desempeno	7
11. Benchmark de Modelos y Seleccion del Ganador	8
12. Serializacion y MVP	9
13. Validacion Backtest e Interpretacion Correcta	10
14. Explicabilidad	11
15. Impacto de Negocio	12
16. Privacidad, Gobernanza y Uso Responsable	12
17. Monitoreo y Criterio de Reentrenamiento	13
18. Conclusiones	13

1. Resumen Ejecutivo

Este informe presenta una version integrada y desarrollada del proyecto de identificacion de clientes premium sobre Olist. El trabajo cubre la cadena completa de valor analitico: comprension del problema de negocio, auditoria de calidad de datos, definicion del target, construccion de un pipeline reproducible, entrenamiento supervisado, seleccion del modelo final, despliegue de un MVP y definicion de criterios de monitoreo y gobernanza.

El problema central consistio en identificar clientes de alto valor en una plataforma donde la mayor parte de la poblacion presenta una sola compra, lo que reduce la utilidad de variables tradicionales de recurrencia. A partir de este hallazgo se definio un target binario *is_premium*, calculado con el percentil 80 del gasto acumulado sobre pedidos entregados y congelado en BRL **197.01**. Esta definicion produce un segmento premium del **20 %** de los clientes que concentra el **56.03 %** de la facturacion, con un ticket promedio **4.36 veces** superior al regular.

El baseline inicial de regresion logistica obtuvo un ROC-AUC de **0.5355**, validando que el problema no podia resolverse con un esquema basico de variables RFMT. La construccion de nuevas variables operativas, logisticas, geograficas, de categoria y de comportamiento de pago permitio elevar el rendimiento hasta un ROC-AUC de **0.7929** y Gini de **0.5858**. Posteriormente, un benchmark de cinco algoritmos y una optimizacion de hiperparametros con Optuna consolidaron a LightGBM como modelo final, con ROC-AUC de validacion **0.8081**, Gini **0.6162** y umbral de decision **0.55**.

Finalmente, el modelo se integro en un MVP funcional con dashboard en Streamlit y API en FastAPI, ambos apoyados en el mismo artefacto serializado. En una simulacion de negocio, la estrategia focalizada mejoro el ROI desde **-89.57 %** en una campana masiva hasta **+250.40 %**. El informe cierra con lineamientos de privacidad, sesgo, monitoreo y reentrenamiento para sostener la utilidad del modelo frente a cambios del mercado.

2. Introduccion

La segmentacion de clientes de alto valor es una practica comun en marketing analitico, pero su efectividad depende de la calidad de la definicion del segmento y del poder real de las variables disponibles. En plataformas de comercio electronico es frecuente asumir que los clientes mas valiosos son tambien los mas recurrentes, pero esa hipotesis no siempre se sostiene. El caso Olist presenta precisamente ese desafio: una gran parte de la base realiza una sola compra, y dentro de esa misma estructura aparecen clientes que concentran valor por el monto de una transaccion, no por su repeticion.

El objetivo de este proyecto fue desarrollar un sistema predictivo que permitiera identificar clientes premium a nivel `customer_unique_id` usando informacion historica disponible en el ecosistema de Olist. El sistema debia ser tecnicamente reproducible, defendible desde negocio y suficientemente interpretable para integrarse en una demostracion funcional.

Para cumplir este objetivo se siguio una estrategia incremental:

1. perfilar datos crudos y entender sus limitaciones;

2. definir y defender un target premium estadística y comercialmente consistente;
3. convertir notebooks exploratorios en un pipeline reproducible;
4. enriquecer el espacio de variables para resolver la baja capacidad del baseline;
5. comparar algoritmos y seleccionar un modelo final;
6. desplegar un MVP con explicabilidad y simulación financiera;
7. proponer criterios de gobernanza, monitoreo y reentrenamiento.

3. Problema de Negocio y Objetivo Analítico

Olist opera como un integrador de vendedores dentro del comercio electrónico brasileño. En este contexto, identificar clientes con alta probabilidad de pertenecer al segmento premium tiene implicaciones directas sobre:

- asignación de presupuesto comercial,
- priorización de campañas de retención,
- venta cruzada sobre categorías de alto valor,
- reducción de desperdicio en estrategias masivas.

El objetivo analítico no fue predecir compras futuras en sentido causal estricto, sino construir un scoring operativo que distinguiera a los clientes con mayor afinidad al segmento premium en función de sus patrones históricos observados.

La hipótesis inicial de trabajo era que el valor premium podría inferirse desde frecuencia, recencia, calificaciones, comportamiento de pago y logística. Sin embargo, el propio análisis de datos mostró que la frecuencia pura era un discriminador mucho menos potente de lo esperado, obligando a una reformulación del enfoque.

4. Datos y Perfilado de Calidad

El proyecto utilizó siete datasets crudos: clientes, órdenes, pagos, reseñas, productos, vendedores e ítems de compra. El perfilado inicial tuvo dos objetivos: evaluar consistencia física y temporal, y entender si la estructura del negocio apoyaba o no la intuición del target premium.

4.1. Valores faltantes e inconsistencias

Se detectaron nulos significativos en campos de texto de reseñas y en algunas fechas logísticas, pero la principal alerta provino de inconsistencias cronológicas dentro del ciclo de vida de las órdenes. Entre los casos observados estuvieron:

- entregas al transportista antes de la aprobacion del pago,
- registros de recepcion por parte del cliente anteriores a la etapa logistica,
- discrepancias entre fechas de compra, aprobacion y entrega.

Estas observaciones no invalidan el dataset, pero justifican reglas de saneamiento y cautela al disenar variables temporales.

4.2. Asimetria monetaria y cola larga

El gasto acumulado por cliente presento una distribucion marcadamente asimetrica, con *skewness* aproximada de **7.92**. Esta propiedad hizo poco recomendable definir segmentos con promedios o umbrales sensibles a valores extremos. Por ello, el uso de percentiles robustos resulto metodologicamente mas apropiado.




Figura 1: Distribucion del gasto acumulado neto por cliente. La cola larga justifica una segmentacion basada en percentiles robustos.

4.3. La paradoja del target

El hallazgo mas importante del perfilado fue que aproximadamente el **97 %** de los clientes tenia solo una orden. Este hecho altera la intuicion habitual de CRM: los clientes premium en Olist no necesariamente son mas recurrentes, sino que muchas veces se distinguen por una compra unica de alto valor. Este comportamiento fue denominado internamente **Paradoja del Target** y se convirtio en el eje conceptual de todo el modelado posterior.

5. Definicion del Target Premium

La variable objetivo se definio sobre el gasto acumulado de pedidos con estado delivered. El target final fue:

$$is_premium = \begin{cases} 1 & \text{si } total_spent \geq P80_{dev} = 197,01 \\ 0 & \text{en caso contrario} \end{cases} \quad (1)$$

La decision de usar el percentil 80 respondio a criterios tecnicos y de negocio:

- conserva una proporcion premium cercana al 20 %;
- evita un segmento excesivamente amplio o demasiado estrecho;
- se adapta mejor a la asimetria del gasto;
- es interpretable desde negocio como una segmentacion de alto valor.

Tambien se decidio congelar el umbral sobre el conjunto de desarrollo. De este modo, el target no cambia en cada corrida y las comparaciones entre experimentos permanecen consistentes.

Cuadro 1: Resumen del Target Premium

Indicador	Valor
Cientes totales	96,096
Cientes premium	19,220
Proporcion premium	20.00 %
Umbral P80 congelado	BRL 197.01

6. Validacion del Segmento desde Negocio

Una definicion de target solo es defendible si produce un segmento economicamente relevante. En este caso, la validacion de negocio fue clara: el 20 % premium concentra el **56.03 %** de la facturacion, con un ticket promedio de BRL **402.66** frente a BRL **92.27** del segmento regular.

Cuadro 2: KPIs de Negocio por Segmento

Indicador	Premium	Regular
Cientes	19,220	76,876
Participacion base	20.00 %	80.00 %
Facturacion	BRL 8,088,731.72	BRL 6,348,315.77
Participacion facturacion	56.03 %	43.97 %
Ticket promedio	BRL 402.66	BRL 92.27

Estos resultados sostienen que el target no es una construccion arbitraria. El segmento detectado tiene sentido comercial y justifica el esfuerzo de clasificacion.

7. Arquitectura del Pipeline Reproducible

Una de las prioridades del proyecto fue convertir el trabajo exploratorio inicial en un pipeline modular y reutilizable. La arquitectura final quedo estructurada en cuatro pasos:

1. `src/data/build_master_table.py`
2. `src/features/build_rfm_features.py`
3. `src/features/feature_selection_experiments.py`
4. `src/models/evaluate_model.py`

Este diseno ofrece varias ventajas:

- separacion clara entre construccion de datos, creacion de variables y modelado;
- persistencia de artefactos intermedios;
- trazabilidad de cada etapa;
- reuso del mismo flujo sobre desarrollo, validacion y backtest.

La master table final se consolido a nivel de `customer_unique_id` y quedo libre de duplicados. Sobre ella se construyeron 18 variables derivadas adicionales.

8. Ingenieria de Variables

Para superar la limitacion del baseline inicial se enriquecio el espacio de variables con cuatro grandes familias:

- **Composicion del pedido:** intensidad y diversidad de items;
- **Pago y financiamiento:** cuotas, metodos y complejidad de pago;
- **Logistica y servicio:** retrasos, cancelaciones, brechas de entrega;
- **Contexto geografico y de categoria:** region, categoria principal y categorias de alto valor.

Entre las variables mas relevantes estuvieron `installments_gt_1_flag`, `credit_card_flag`, `delivery_gap`, `far_region_flag`, `top_category_group` y `top_category_is_high_value`.

El control de leakage se mantuvo como restriccion permanente. No se permitieron variables que reconstruyeran directamente el gasto objetivo ni identificadores operativos que inflaran artificialmente el poder predictivo.

9. Seleccin Experimental de Variables

La seleccin final no se hizo por criterio manual, sino mediante ocho experimentos reproducibles. El corte temporal oficial de evaluacion fue **2018-07-01**, separando entrenamiento y validacion de forma cronologica.

El experimento ganador fue `corr_le_0.85`, con **28 variables**. Su ventaja no fue solo el mejor equilibrio de desempeno, sino tambien la mayor parsimonia frente a sets mas grandes con ganancia marginal en AUC.




Figura 2: Comparacion de experimentos de seleccion de variables. El set final retiene alta capacidad predictiva con menor redundancia.

10. Baseline y Mejora del Desempeno

El baseline inicial fue una regresion logistica con ponderacion balanceada de clases. Su desempeno fue:

- Precision: 0.30
- Recall: 0.16
- F1-Score: 0.21
- ROC-AUC: 0.5355

Lejos de ser un fracaso, este resultado fue diagnostico: confirmo que las variables basicas no eran suficientes para capturar el segmento premium dentro de la estructura de Olist.

Al incorporar las nuevas variables y el set final seleccionado, el modelo de referencia del pipeline alcanzo:

- Precision: 0.4766
- Recall: 0.6294

- F1-Score: 0.5424
- ROC-AUC: 0.7929
- Gini: 0.5858

Cuadro 3: Comparacion de Metricas: Baseline vs. Pipeline Enriquecido

Metrica	Baseline	Pipeline enriquecido
Precision	0.3000	0.4766
Recall	0.1600	0.6294
F1-Score	0.2100	0.5424
ROC-AUC	0.5355	0.7929
Gini	0.0710	0.5858




Figura 3: Curva ROC del baseline. Su cercanía al azar justifico la necesidad de enriquecer el espacio de variables.

11. Benchmark de Modelos y Seleccion del Ganador

Una vez estabilizado el pipeline, se compararon cinco modelos candidatos:

1. Regresion Logistica
2. Random Forest

3. Gradient Boosting

4. XGBoost

5. LightGBM

Los criterios de comparacion incluyeron ROC-AUC, Gini, F1, Recall y gap de sobre-ajuste. Este punto es importante: no se selecciono el modelo solo por AUC. En un contexto de negocio, dejar de detectar clientes premium tiene un costo alto, por lo que el Recall y el F1 debian influir en la decision.

LightGBM y XGBoost quedaron como finalistas. Luego se aplico Optuna TPE con 50 *trials* por modelo. LightGBM se consolido como ganador por liderar las metricas de discriminacion global con estabilidad razonable.

Cuadro 4: Resultado del Modelo Final

Indicador	Valor
Modelo final	LightGBM tuneado
ROC-AUC validacion	0.8081
Gini validacion	0.6162
Umbral operativo	0.55




Figura 4: Benchmark de modelos candidatos. LightGBM y XGBoost dominaron el ranking final.

12. Serializacion y MVP

El modelo final fue serializado como `modelo_final.pkl`. Sobre este artefacto se construyo un MVP con dos capas:

- un dashboard en Streamlit para exploracion, scoring y explicacion visual;

- una API en FastAPI para inferencia estructurada.

Ambas superficies consumen el mismo modelo y el mismo esquema de variables. Esta consistencia fue una condicion clave para la trazabilidad tecnica del proyecto.




Figura 5: Arquitectura del MVP. El pipeline prepara el dataset y tanto dashboard como API reutilizan el mismo artefacto del modelo.

13. Validacion Backtest e Interpretacion Correcta

La validacion final del MVP se hizo sobre un backtest formal de agosto de 2018. El split tecnico historico `holdout_3m` se conserva por trazabilidad, pero septiembre y octubre solo aportan 20 ordenes combinadas y no constituyen una base seria para evaluacion final. Las metricas observadas sobre el backtest fueron:

- ROC-AUC: 0.9876
- Gini: 0.9751
- Precision: 43.80 %
- Recall: 56.11 %
- F1-Score: 49.20 %

Este rendimiento debe explicarse con rigor. No significa automaticamente que el modelo generaliza mucho mejor que en validacion. La interpretacion mas defendible es que agosto de 2018 presenta una estructura mas separable y que la etiqueta premium esta fuertemente ligada a senales transaccionales. Por tanto, el backtest debe verse como validacion de integracion, scoring y utilidad del MVP, no como unica prueba metodologica del modelo.

Cuadro 5: Metricas Tecnicas sobre Backtest

Metrica	Valor
ROC-AUC	0.9876
Gini	0.9751
Precision	43.80 %
Recall	56.11 %
F1-Score	49.20 %

Como lectura adicional de negocio, tambien se construyo una tabla *lift/gain* en 10 deciles del backtest. El hallazgo fue especialmente extremo: el primer decil ya captura el 100 % de los premium reales del corte evaluado y alcanza un **lift de 10.00x**. Es importante explicarlo bien: esto no significa que el primer decil sea 100 % premium, sino que su tasa premium interna sube a **13.04 %** frente a una tasa base total de solo **1.30 %**. Dicho de otro modo, el ranking del modelo multiplica por diez la densidad esperada de premium en el tramo mas alto del score, lo que lo vuelve muy util para priorizacion comercial, pero al mismo tiempo confirma que agosto de 2018 es un escenario historico mucho mas facil que la validacion metodologica principal.

14. Explicabilidad

El proyecto incorporo explicabilidad local y global. La explicabilidad local permite auditar por que un cliente obtuvo determinado score. La explicabilidad global, mediante SHAP, permitio identificar las senales dominantes del modelo final.

Las variables mas influyentes del SHAP global fueron:

- `delivered_orders`
- `max_payment_installments`
- `total_items`
- `top_category_is_high_value`

Esto refuerza que el modelo no es una caja negra opaca. La prediccion puede trazarse a variables que negocio entiende y puede discutir.

15. Impacto de Negocio

Para traducir el score a una decision comercial, se compararon dos estrategias:

1. campana masiva sobre toda la base;
2. campana focalizada sobre clientes con probabilidad $\geq 0,55$.

El contraste es suficientemente fuerte como para argumentar valor de negocio del modelo. La estrategia focalizada reduce drasticamente el costo comercial y convierte una campana inviable en una accion con retorno positivo.




Figura 6: SHAP Summary Plot del modelo final. Las principales senales son transaccionales y de comportamiento comercial.

Cuadro 6: Comparativa de Estrategias Comerciales

Metrica	Masiva	Focalizada
Clientes contactados	96,096	1,605
Costo de campana	BRL 1,441,440.00	BRL 24,075.00
Ingreso por conversiones	BRL 150,360.00	BRL 84,360.00
Utilidad neta	BRL -1,291,080.00	BRL 60,285.00
ROI	-89.57 %	+250.40 %

16. Privacidad, Gobernanza y Uso Responsable

El analisis etico del proyecto se centro en dos preguntas:

1. si el modelo usa o no datos sensibles directos;
2. si las variables que si retiene pueden generar sesgos operativos.

El modelo final no entrena con identificadores directos como `customer_unique_id`, `customer_city` o `customer_zip_code_prefix`. Tampoco utiliza datos financieros sensibles directos como numeros de tarjeta o cuentas bancarias. Sin embargo, conserva variables como `customer_state`, `main_payment_type` o `max_payment_installments`, que pueden actuar como proxies de desigualdad geografica o bancarizacion.

Por ello, la recomendacion de gobernanza es:

- usar el score como apoyo a priorizacion comercial y no como criterio automatico unico;
- monitorear distribuciones por region y metodo de pago;
- minimizar exposicion de identificadores tecnicos;

- exigir cifrado y control de acceso si el MVP se operativiza en un contexto real.

17. Monitoreo y Criterio de Reentrenamiento

El modelo fue entrenado con historia y, por tanto, no debe asumirse valido indefinidamente. La utilidad futura depende de que la relacion entre comportamiento de compra, logistica, pagos y definicion del segmento premium permanezca estable.

Se recomienda monitorear:

- desempeno discriminativo: ROC-AUC, Gini, Precision, Recall;
- impacto comercial: ROI de la campana focalizada;
- estabilidad poblacional: tasa premium predicha y volumen priorizado;
- drift de variables clave: `delivered_orders`, `total_items`, `max_payment_installments`, `customer_state`, `top_category_is_high_value`.

El criterio recomendado no es reentrenar por calendario fijo, sino por evidencia. Una regla operativa inicial puede ser:

- alerta amarilla si el Gini cae mas de 20 % respecto al baseline;
- alerta roja si ademas cae el ROI o cambia bruscamente la tasa premium predicha;
- revision obligatoria si varias variables dominantes muestran drift simultaneo.

Cuando se confirme degradacion, el nuevo entrenamiento debe hacerse sobre una ventana temporal nueva y completa, separada del periodo que entreno el artefacto vigente.

18. Conclusiones

El proyecto demostro que la identificacion de clientes premium en Olist es viable cuando se aborda con una arquitectura de datos y modelado coherente con la estructura real del negocio.

Las conclusiones principales son:

1. El perfilado inicial mostro que la recurrencia no era la senal principal del valor premium, lo que obligo a abandonar una lectura simplista del RFM tradicional.
2. La definicion del target mediante P80 congelado produjo un segmento estadistica y comercialmente defendible.
3. La ingenieria de variables y el pipeline reproducible permitieron transformar un baseline casi aleatorio en un sistema predictivo util.
4. LightGBM ofrecio la mejor combinacion de discriminacion, estabilidad y capacidad operativa.

5. El MVP demostro que el modelo puede integrarse a una capa funcional con explicabilidad y simulacion de ROI.
6. La sostenibilidad del modelo depende de monitoreo, gobernanza y reentrenamiento basado en evidencia, no en calendario.

Como siguiente etapa natural, el proyecto podria evolucionar hacia:

- monitoreo historico mensual en dashboard;
- validaciones temporales mas estrictas con ventanas completas;
- captura de ROI observado en operacion real;
- politicas mas formales de fairness, cifrado y auditoria.