





Arquitectura del Pipeline Reproducible de Sprint 2

El Sprint 2 transforma fuentes dev/raw en artefactos persistidos mediante un flujo modular de construcción, enriquecimiento, selección y evaluación.

El flujo principal se ejecuta sobre dev para construcción, selección y evaluación. La rama holdout reutiliza el umbral fijo para validar estabilidad operativa en una nueva ventana temporal.




RESUMEN DE MEJORA DEL MODELO

ROC-AUC	Gini	F1-score
		


La mejora se logró con un set final de 28 variables seleccionado mediante experimentación reproducible, con control explícito de colinealidad y fuga de información.

Evolución de Artefactos del Pipeline



El pipeline preserva la granularidad por cliente, amplía el espacio de atributos y reduce la dimensionalidad final mediante selección experimental reproducible.

DEFINICIÓN DEL TARGET: UMBRAL PREMIUM P80



BRL 197.01 UMBRAL PREMIUM

Variable objetivo: is_premium

Tasa premium observada en dev: ~20%

Regla: percentil 80 del gasto acumulado de pedidos delivered. **Política:** el umbral se calcula una sola vez en dev (fit) y luego se reutiliza con apply.

Mensaje de negocio: En dev, el 20% premium concentra el 56.03% de la facturación observada.

Interpretación: El corte P80 equilibra interpretabilidad de negocio, estabilidad metodológica y comparabilidad entre corridas del pipeline.


Perfilado de la Master Table Raw

La construcción de la master table raw permitió identificar nulos concentrados en variables financieras, logísticas y de pago antes del modelado.

Clúster de Logística y Valor



Clúster de Pagos



El Sprint 2 no resolvió estos faltantes mediante imputación masiva **sin criterio**.

En su lugar, formalizó un **perfilado reproducible y una limpieza mínima trazable para preservar la lógica del pipeline**.

Ingeniería de Variables: 18 Nuevas Señales del Sprint 2

Composición de pedido

- items_per_order
- products_per_order
- max_to_avg_price_ratio

Flete y logística

- freight_to_item_ratio
- delivery_gap
- has_late_delivery
- has_cancellation

Pago y cuotas

- installments_gt_1_flag
- installments_gt_6_flag
- credit_card_flag
- boleto_flag
- voucher_flag
- payment_complexity_flag

Experiencia

- reviews_per_order

Geografía

- region_group
- far_region_flag

Categoría

- top_category_group
- top_category_is_high_value

“top_category_is_high_value se definió con el cuartil superior de avg_item_price por categoría para evitar fuga del target.”

Selección Experimental de Variables

Experimento	# Features	AUC Validación	Gini Validación
initial	37	0.7939	0.5878
missing_le_0.10	37	0.7939	0.5878
corr_le_0.95	32	0.7922	0.5845
corr_le_0.90	29	0.7923	0.5846
corr_le_0.85	28	0.7921	0.5843
univariate_top_30pct	12	0.7752	0.5503
univariate_top_20pct	8	0.7686	0.5372
univariate_top_10pct	4	0.7430	0.4860

corr_le_0.85 fue seleccionado porque reduce el set de 37 a 28 variables con una caída mínima en AUC de validación (0.0018), mejorando la parsimonia y la defendibilidad metodológica.



Configuración Seleccionada: corr_le_0.85

Parsimonia

37 features



28 features

Reducción de 37 a 28 variables.

Disminución de redundancia interna.
Set más simple de explicar y mantener.

Desempeño

AUC validación inicial =

0.7939

AUC validación

corr_le_0.85 = 0.7921

Pérdida mínima de solo
0.0018.

Defendibilidad metodológica

Menor colinealidad.
Mejor equilibrio entre complejidad y señal predictiva.

Selección sustentada por experimentación reproducible.

corr_le_0.85 fue elegido porque preserva casi toda la capacidad predictiva del set completo, con menos variables y mejor parsimonia.

Blueprint Final de Variables: Conservadas vs. Excluidas

Variables excluidas por leakage o proximidad al target (13)

- total_spent
- avg_ticket
- avg_order_price
- avg_item_price
- max_item_price
- avg_freight_value
- avg_freight_ratio
- freight_to_item_ratio
- customer_unique_id
- first_purchase
- last_purchase
- customer_city
- customer_zip_code_prefix

is_premium se mantiene como variable objetivo y no forma parte del set de predictores.

Set final de modelado (28 features)

Operativas: total_orders, total_items, total_products, delivered_orders

Temporales: recency_days, customer_lifetime_days


Logísticas y experiencia: avg_delivery_days, avg_estimated_delivery_days, late_deliveries, delivery_gap, reviews_per_order, cancellation_rate

Pago y cuotas: payment_methods_count, max_payment_installments, installments_gt_1_flag, installments_gt_6_flag, credit_card_flag, voucher_flag, main_payment_type

Producto y geografía: products_per_order, max_to_avg_price_ratio, far_region_flag, top_category_is_high_value, customer_state, top_category, region_group, top_category_group

El set final conserva señales de comportamiento, pago, logística y categoría, evitando reconstruir directamente el target.


Resultado Final del Modelo en Validación Dev



Predicho		
Negativo	Positivo	
Real	Negativo	TN Negativo Verdadero 3825
	Positivo	FP Positivo Falso 983
Real	Negativo	FN Negativo Falso 527
	Positivo	TP Positivo Verdadero 895

Comparación Final de Separabilidad del Modelo

El Sprint 2 mejora de forma sustancial la capacidad de discriminación del clasificador frente al baseline del Sprint 1.



La mejora simultánea en ROC-AUC y Gini confirma una ganancia real en separabilidad, consistente con la curva ROC comparativa y con la selección experimental de variables.