


# Identificación de Clientes Premium

---

Sprint 3: Hiperparametrización y Selección del Modelo Final

---

**Integrantes:** Marcelo de la Quintana, Gaston Nina, Gerick Toro | Maestría en IA y Ciencia de Datos



# 56.03%

# 20%

de la base de clientes

de la **facturación total**

El **segmento** que define la rentabilidad de Olist.



Ticket promedio **4.36x**  
superior

(BRL 402.66 vs. BRL 92.27)



# El obstáculo: Predecir sin historial



Compra única.  
Sin historial de repetición.



**La Paradoja del Target:** ¿Cómo detectamos un cliente de alto valor si los modelos tradicionales exigen medir la frecuencia? La señal debe extraerse de patrones logísticos, métodos de pago y elección de producto en esa única transacción.



# Un cliente premium no detectado es un cliente perdido

Maximizar el Recall es nuestra métrica de negocio intransigente.

| Predicción     |                    |
|----------------|--------------------|
| Realidad       | Verdadero Positivo |
|                | Falso Positivo     |
| Falso Negativo | Verdadero Negativo |

☺ **Verdadero Positivo**

Cliente Premium  
Detectado Correctamente

**Falso Positivo**

**Costo:** Bajo. Beneficio  
ofrecido a cliente regular.

**Falso Negativo**

**Costo: Crítico.** Cliente de  
altísimo valor perdido.

**Verdadero Negativo**

Cliente Regular  
Detectado Correctamente



# Matriz de Confusión del Modelo Final: Interpretación con Datos Reales

El modelo final prioriza la detección de clientes premium, aceptando un trade-off controlado entre cobertura y precisión.

LightGBM Tuneado — Matrices de Confusión (validación)

Umbral = 0.5  
Recall=0.662 Precision=0.489

|            |         |                 |         |
|------------|---------|-----------------|---------|
| True label | regular | 3824            | 984     |
|            | premium | 481             | 941     |
|            |         | regular         | premium |
|            |         | Predicted label |         |

Umbral = 0.55  
Recall=0.602 Precision=0.529

|            |         |                 |         |
|------------|---------|-----------------|---------|
| True label | regular | 4046            | 762     |
|            | premium | 566             | 856     |
|            |         | regular         | premium |
|            |         | Predicted label |         |

Esta configuración optimiza el Recall para asegurar la retención de clientes premium, minimizando el impacto de falsos negativos.

## Interpretación Ejecutiva

- **Falsos Negativos (Costo Crítico):** Se minimizan para evitar la pérdida de clientes de alto valor, nuestra prioridad de Recall.
- **Falsos Positivos (Costo Bajo):** Aceptamos un mayor número para asegurar la captura de los clientes premium, ofreciendo beneficios a clientes regulares.
- **Trade-off Estratégico:** La matriz refleja la decisión de negocio de priorizar la cobertura sobre la precisión absoluta. Esto prepara el análisis del umbral óptimo.



# La audición técnica: 5 candidatos en el punto de partida

| Modelo              | Tipo     | ROC-AUC  | Gap de Overfit |
|---------------------|----------|----------|----------------|
| LightGBM            | Boosting | 0.8035 ↑ | 0.0370 ↓       |
| Gradient Boosting   | Boosting | 0.7985   | 0.0274         |
| XGBoost             | Boosting | 0.7982   | 0.0290         |
| Random Forest       | Bagging  | 0.7926   | 0.0191         |
| Regresión Logística | Lineal   | 0.7884   | 0.0156         |

Condiciones idénticas: 28 variables preprocesadas, corte temporal 2018-07-01. Todos mantienen generalización estable.



# Cuidado con el espejismo estadístico

ROC-AUC: 0.7985

2do  
lugar

Recall: 0.33


**El veredicto:** A pesar de su excelente ROC-AUC, este modelo dejaría sin detectar al 67% de los clientes premium reales. Inaceptable para el negocio. **Descartado.**



# De la intuición a la hiperparametrización Bayesiana

Finalistas: LightGBM y XGBoost. Motor: Optuna TPE.

## Fuerza Bruta (GridSearch)



## Optimización Bayesiana (TPE)

50 trials iterativos hacia el hiperespacio ideal.





# Punto de Inflexión Metodológico: Optimización con Optuna

Reemplazamos la intuición por una búsqueda sistemática guiada por evidencia.




**Ajuste Manual  
(Intuición)**

Explora  
ciegamente,  
costoso,  
ineficiente.



**Optuna  
(Evidencia)**

Búsqueda  
guiada,  
eficiente,  
reproducible.



Historial de Optimización de Optuna  
(LightGBM)

- Finalistas: LightGBM y XGBoost
- Motor: Optuna TPE
- 50 trials por modelo
- Objetivo: maximizar ROC-AUC en validación
- Búsqueda guiada por resultados previos
- Proceso reproducible

La **optimización sistemática con Optuna** garantizó una mejora robusta y reproducible del modelo.



# Resultados de la Hiperparametrización

## LightGBM

### Baseline

ROC-AUC: 0.8035

F1: 0.5565

Gap: 0.0370



### Tuneado

**ROC-AUC:  
0.8081**

F1: 0.5576

Gap: 0.0385 (Estable)

## XGBoost

### Baseline

ROC-AUC: 0.7982

F1: 0.5504

Gap: 0.0290



### Tuneado

ROC-AUC: 0.8070

F1: 0.5560

Gap: 0.0525 (Subió)

**Nota:** XGBoost mejoró su discriminación global, pero Optuna sacrificó su Recall (cayó a 0.6371). LightGBM mantuvo el balance perfecto.



# La decisión técnica: **LightGBM**

## Poder Predictivo


ROC-AUC Máximo de 0.8081 y Gini de 0.6162.  
Lidera en discriminación global.



## LightGBM

## Estabilidad Superior

Gap de overfit rigurosamente controlado en 0.0385 (muy por debajo del límite de riesgo).



## Eficiencia Operativa

Velocidad de entrenamiento drásticamente superior a XGBoost, facilitando las iteraciones de reentrenamiento mensual.



**Nota:** Selección basada en rendimiento y viabilidad a largo plazo.



# ¿Qué hace a un cliente **Premium**?




## Interpretación de Negocio

-  1. El **QUÉ compra**: Las categorías de alto valor (electrónica, relojes) dictan el estatus, no el volumen de ítems.
-  2. El **CUÁNDO compra**: Los clientes más recientes impulsan el volumen del segmento.

**La Paradoja resuelta:** Estas dos variables concentran el 43% de la capacidad predictiva.



# Calibrando el umbral para el negocio



**Umbral por defecto (0.50):**  
Demasiados falsos positivos,  
afectando la eficiencia comercial.



**Umbral Óptimo (0.55):**  
Maximiza el F1-Score general.



**Impacto Operativo:** Detecta a 6  
de cada 10 premium reales  
(Recall 0.60) mientras afina  
significativamente la precisión  
(0.52) de futuras campañas.



# Pipeline serializado y preparado para producción



Integra el preprocesamiento de las 28 variables y el motor LightGBM tuneado de forma autónoma. Supera en 1.52 puntos de ROC-AUC al baseline anterior.

**Solución defendible, reproducible y lista para integrarse.**