


# Identificación de Clientes Premium en Olist: del modelo al MVP

Demo Day Sprint 4: Identificación de Clientes Premium





## La Curva de Pareto

El **20%** de los clientes (19,220) genera el **56.03%** de la facturación total de Olist.

### Paradoja del Target

El 97% de los clientes tiene una única orden. Las métricas clásicas fallan.

### Ticket Promedio

BRL 402.66 (Premium) vs BRL 92.27 (Regular)

Una diferencia sustancial de **4.36x**.



# El Objetivo: Identificar el Segmento de Alto Valor

## Variable Objetivo

is\_premium (Clasificación Binaria)

## Criterio de Decisión

Gasto neto acumulado por cliente  $\geq$  Percentil 80.

Umbral P80

## Umbral Fijo Matemático

**BRL 197.01**

Persistido estable desde la población de desarrollo para focalizar recursos y evitar desperdicio comercial.



# Fundamentos Técnicos (Sprints 1 y 2): De la Exploración al Pipeline Reproducible

## Paso 1: Resolución de Fuga de Datos

Exclusión estricta de variables directas (`total_spent`, `avg_ticket`) para evitar el data leakage y garantizar validez.

## Paso 2: Selección Experimental

Reducción de dimensionalidad a 28 variables clave (Experimento `corr_le_0.85`), eliminando colinealidad interna.

## Paso 3: Salto Predictivo

Mejora sustancial de clasificación. El ROC-AUC evoluciona desde el baseline logístico (0.5355) al pipeline validado (0.7929).



# El Cerebro del Sistema (Sprint 3): Optimización LightGBM

## Motor de Predicción

LightGBM optimizado vía Optuna TPE (50 trials explorados). Seleccionado sobre XGBoost por velocidad de entrenamiento, eficiencia operativa y menor gap de sobreajuste (0.039).



## Discriminación Global

**ROC-AUC: 0.8081**

**Gini: 0.6162**

## Calibración Comercial

Umbral de decisión fijado en 0.55

Maximiza el F1-Score (0.5603) equilibrando el Recall (0.6041) para capturar el valor del negocio sin saturar campañas.





# La Arquitectura del Pipeline de Datos-a-Decisión





# El Salto al Producto (Sprint 4): De la Experimentación a la Operación



## Entorno de Experimentación (Sprints 1-3)

Validaciones temporales y modelos aislados en notebooks locales.



## Integración Operativa MVP

Reutilización del pipeline analítico sobre el escenario holdout\_3m. El modelo se congela y serializa operativamente.

**Artefacto Central: modelo\_final.pkl**



# Arquitectura del MVP: Flujo de Datos Reutilizable





# Ingeniería de Despliegue: **Contenedorización Aislada**



**Puerto  
8501**

## **Frontend / Dashboard**

**Tecnología:** Streamlit en Python 3.12

**Función:** Interfaz interactiva de usuario, visualización de scoring individual, análisis de variables críticas y panel de impacto ROI.



**Puerto  
8000**

## **Backend / API REST**

**Tecnología:** FastAPI en Python 3.12

**Función:** Endpoints independientes (/health, /predict) para integración programática. Todo el ecosistema orquestado nativamente mediante docker-compose.



# Demo del Dashboard: Navegando el Producto Mínimo Viable



Interfaz incrustando métricas operativas y predictivas en tiempo real.




# Dentro de la Mente del Modelo: La Anatomía de un Cliente Premium

1

## Intensidad de Entrega:

Un alto número de pedidos entregados y artículos totales impulsan fuertemente la puntuación hacia la clasificación Premium.

- delivered\_orders
- max\_payment\_installments
- total\_items
- top\_category\_cama\_mesa\_banho
- top\_category\_is\_high\_value
- reviews\_per\_order
- avg\_delivery\_days
- credit\_card\_flag
- main\_payment\_type\_boleto
- installments\_gt\_1\_flag
- avg\_estimated\_delivery\_days
- top\_category\_telefonia



2

## Comportamiento de Pago:

El alto uso de cuotas indica poder adquisitivo y se correlaciona fuertemente con el estatus Premium.

3

## Selección de Productos:

Las compras en categorías específicas de gama alta son indicadores masivos de valores de ticket premium.

**El modelo confirma que el estatus Premium en un entorno de compra única está impulsado por la densidad del carrito, el uso de cuotas y las categorías de productos de alto valor.**



# Explicabilidad (SHAP): La Anatomía del Cliente Premium

**delivered\_orders**  
(Intensidad transaccional)

**max\_payment\_installments**  
(Capacidad crediticia y cuotas)

**total\_items**  
(Volumen de productos)

**top\_category\_is\_high\_value**  
(Afinidad por relojes, electrónica)

**Score  
Premium**

Potencial de Alto Valor

**Mensaje Clave:** La caja de cristal. El modelo es completamente transparente y acciona sobre comportamiento logístico y transaccional real, sin basarse en suposiciones ocultas.



## Estándar de Calidad: El Rendimiento Metodológico Base (Sprint 3)

**ROC-AUC**

**0.8081**

**Gini**

**0.6162**

**Recall** (Umbral 0.55)

**0.6041**

**Precision** (Umbral 0.55)

**0.5225**

**Postulado Científico:** Esta validación temporal representa la verdad fundamental y el estándar de generalización puro del modelo frente a una población heterogénea.  
Es el baseline metodológico inmutable.



# Validación Operativa: Desempeño sobre Backtest Formal (Agosto de 2018)

**ROC-AUC**

**0.9876**

Gini: 0.9751

**Precision | Recall**

**43.80% | 56.11%**

F1: 49.20%



## Lectura Recomendada del Resultado

- El backtest muestra una separabilidad operativa muy alta en agosto de 2018.
- No se interpreta como reemplazo directo de la validación temporal de Sprint 3.
- Su valor principal es demostrar scoring reproducible, integración del MVP y utilidad para la capa comercial.



# Validación Operativa: Separabilidad en el Escenario Holdout (Sprint 4)

Holdout 3M ROC-AUC

**0.9872**

Gini: 0.9745

Holdout 3M

Precision | Recall

**43.10% | 57.06%**



## Nota Metodológica Crítica

- El elevado ROC-AUC **NO** es una mejora milagrosa ni un sobreajuste del modelo.
- Se debe a una mayor separabilidad estructural del escenario operativo mensual.
- El volumen truncado de transacciones facilita drásticamente la discriminación técnica frente a clientes inactivos.
- El modelo mantiene su robustez integrativa, pero el éxito real debe juzgarse estrictamente por el ROI comercial.



# Impacto Financiero: El Verdadero Valor del Modelo


|                     | Campaña Masiva            | Campaña Optimizada          |
|---------------------|---------------------------|-----------------------------|
| Clientes Impactados | 96,096                    | 1,659                       |
| Costo de Campaña    | BRL 1.44M                 | BRL 24,885                  |
| Utilidad Neta       | <b>Pérdida BRL -1.29M</b> | <b>Ganancia BRL +60,915</b> |
| <b>ROI Final</b>    | <b>-89.57%</b>            | <b>+244.79%</b>             |

El modelo genera una reducción del 98.27% en costos de marketing, logrando un ahorro neto documentado de BRL 1.41 Millones.



# Capacidad de priorización comercial del score

Gain y lift sobre clientes activos en agosto de 2018



|                           |        |
|---------------------------|--------|
| Cientes activos evaluados | 6,460  |
| Premium reales            | 1,253  |
| Tasa base premium         | 19.40% |
| Captura acumulada top 10% | 32.32% |
| Tasa premium en decil 1   | 62.69% |
| Lift del decil 1          | 3.23x  |
| Captura acumulada top 20% | 49.56% |
| Lift acumulado top 20%    | 2.48%  |

El ranking del modelo concentra una parte importante de los clientes premium en los primeros deciles de la base activa. El top 10% captura 32.32% de los premium reales, y el primer decil alcanza una tasa premium de 62.69%, muy superior a la tasa base de 19.40%. Esto muestra **utilidad real para focalización comercial** dentro de la ventana operativa de agosto.

Esta lámina debe leerse como evidencia de priorización comercial sobre clientes activos en agosto de 2018, no como sustituto de la validación temporal principal de Sprint 3.




# Detalle técnico de gain/lift por deciles

Clientes activos en agosto de 2018

| decile   | cases | responses | premium_rate_pct | cum_responses | gain_pct | lift | cum_lift |
|----------|-------|-----------|------------------|---------------|----------|------|----------|
| Decil 1  | 646   | 405       | 62.69%           | 405           | 32.32%   | 3.23 | 3.23     |
| Decil 2  | 646   | 216       | 33.44%           | 621           | 49.56%   | 1.72 | 2.48     |
| Decil 3  | 646   | 167       | 25.85%           | 788           | 62.89%   | 1.33 | 2.10     |
| Decil 4  | 646   | 109       | 16.87%           | 897           | 71.59%   | 0.87 | 1.79     |
| Decil 5  | 646   | 91        | 14.09%           | 988           | 78.85%   | 0.73 | 1.58     |
| Decil 6  | 646   | 89        | 13.78%           | 1077          | 85.95%   | 0.71 | 1.43     |
| Decil 7  | 646   | 62        | 9.60%            | 1139          | 90.90%   | 0.49 | 1.30     |
| Decil 8  | 646   | 62        | 9.60%            | 1201          | 95.85%   | 0.49 | 1.20     |
| Decil 9  | 646   | 37        | 5.73%            | 1238          | 98.80%   | 0.30 | 1.10     |
| Decil 10 | 646   | 15        | 2.32%            | 1253          | 100.00%  | 0.12 | 1.00     |

Clientes activos evaluados en agosto: 6,460 | Premium reales entre activos: 1,253 | Tasa base premium: 19.40%

El **decil 1** contiene 405 premium reales. La tasa premium del decil 1 es 62.69%. El top 10% captura 32.32% de los premium reales. El lift del primer decil es 3.23x.



Esta tabla muestra la capacidad de priorización comercial del score sobre clientes activos en agosto de 2018 y no sustituye la validación metodológica principal del Sprint 3.



# ¿Cuándo reentrenar el modelo?

Criterio operativo de monitoreo y revisión del MVP

## 1. Monitorear desempeño

- No por calendario, sino por evidencia
- Revisar si caen Gini, ROC-AUC, precision o recall en ventanas nuevas

## 2. Detectar deterioro o drift

- Revisar si cae el ROI de la campaña focalizada
- Revisar cambios fuertes en la tasa premium predicha
- Revisar drift en variables clave del negocio

Variables clave: delivered\_orders, total\_items, max\_payment\_installments, customer\_state, top\_category\_is\_high\_value

## 3. Revisar / recalibrar / reentrenar

- Regla inicial: alerta amarilla si Gini cae más de 20% respecto al baseline
- Revisión prioritaria si además cae ROI o cambia bruscamente la tasa premium predicha
- Reentrenar solo con una ventana temporal nueva y completa

Reentrenamos cuando la data nueva deja de parecerse a la historia con la que aprendió el modelo y eso empieza a degradar su capacidad de segmentar con valor de negocio.



# Privacidad, gobernanza y uso responsable del modelo

Qué datos excluimos, qué señales utilizamos y qué controles proponemos



## 1. Qué no usamos

- No usamos identificadores personales directos en el entrenamiento.
- Se excluyeron variables como **customer\_unique\_id**, **customer\_city** y **customer\_zip\_code\_prefix**.
- No usamos datos financieros sensibles directos como números de tarjeta o cuentas bancarias.



## 2. Qué sí usamos

- Usamos variables agregadas de comportamiento comercial y transaccional.
- Ejemplos: **delivered\_orders**, **total\_items**, **top\_category\_is\_high\_value**.
- También usamos algunas señales de contexto como **customer\_state**, **main\_payment\_type** y **max\_payment\_installments**.



## 3. Riesgos residuales

- Algunas variables pueden actuar como proxies de sesgo geográfico o financiero.
- Por eso deben monitorearse efectos no deseados en segmentación y priorización.



## 4. Control operativo

- El score debe usarse como apoyo a decisión comercial.
- No debe operar como automatización ciega.
- Se requiere supervisión humana, versionado del artefacto y monitoreo periódico.

El modelo reduce exposición a datos sensibles directos, pero no elimina por completo el riesgo de sesgo. Por eso proponemos monitoreo continuo y uso supervisado.

“ El modelo no entrena con datos sensibles directos, pero sí requiere monitoreo de proxies y supervisión humana. ”



# Conclusiones y Próximos Pasos en MLOps

## Hito 1: Estado Actual

MVP listo para producción.  
Pipeline reutilizable operando  
en contenedores Docker y  
respaldando un ROI de +244%.

## Hito 2: Monitoreo MLOps

Integración futura con  
herramientas como MLflow  
para versionado de  
experimentos y observabilidad  
real del data drift.

## Hito 3: Reentrenamiento Automatizado

Flujos CI/CD para ejecutar  
entrenamientos mensuales,  
capturando la evolución  
dinámica del  
comportamiento y logística.

“ El Sprint 4 demuestra que el clasificador final ya está integrado, puede explicarse en vivo, y genera una recomendación comercial con sentido económico. ”