


Identificación de Clientes Premium en Olist: del modelo al MVP

Demo Day Sprint 4: Identificación de Clientes Premium





La Curva de Pareto

El **20%** de los clientes (19,220) genera el **56.03%** de la facturación total de Olist.

Paradoja del Target

El 97% de los clientes tiene una única orden. Las métricas clásicas fallan.

Ticket Promedio

BRL 402.66 (Premium) vs BRL 92.27 (Regular)

Una diferencia sustancial de **4.36x**.

El Objetivo: Identificar el Segmento de Alto Valor

Variable Objetivo

is_premium (Clasificación Binaria)

Criterio de Decisión

Gasto neto acumulado por cliente $\geq$ Percentil 80.

Umbral P80

Umbral Fijo Matemático

BRL 197.01

Persistido estable desde la población de desarrollo para focalizar recursos y evitar desperdicio comercial.

Fundamentos Técnicos (Sprints 1 y 2): De la Exploración al Pipeline Reproducible

Paso 1: Resolución de Fuga de Datos

Exclusión estricta de variables directas (`total_spent`, `avg_ticket`) para evitar el data leakage y garantizar validez.

Paso 2: Selección Experimental

Reducción de dimensionalidad a 28 variables clave (Experimento `corr_le_0.85`), eliminando colinealidad interna.

Paso 3: Salto Predictivo

Mejora sustancial de clasificación. El ROC-AUC evoluciona desde el baseline logístico (0.5355) al pipeline validado (0.7929).

El Cerebro del Sistema (Sprint 3): **Optimización LightGBM**

Motor de Predicción

LightGBM optimizado vía Optuna TPE (50 trials explorados). Seleccionado sobre XGBoost por velocidad de entrenamiento, eficiencia operativa y menor gap de sobreajuste (0.039).



Discriminación Global

ROC-AUC: 0.8081

Gini: 0.6162

Calibración Comercial

Umbral de decisión fijado en 0.55

Maximiza el F1-Score (0.5603) equilibrando el Recall (0.6041) para capturar el valor del negocio sin saturar campañas.



La Arquitectura del Pipeline de Datos-a-Decisión



El Salto al Producto (Sprint 4): De la Experimentación a la Operación



Entorno de Experimentación (Sprints 1-3)

Validaciones temporales y modelos aislados en notebooks locales.



Integración Operativa MVP

Reutilización del pipeline analítico sobre el escenario holdout_3m. El modelo se congela y serializa operativamente.

Artefacto Central: modelo_final.pkl

Arquitectura del MVP: Flujo de Datos Reutilizable



Ingeniería de Despliegue: **Contenedorización Aislada**



**Puerto
8501**

Frontend / Dashboard

Tecnología: Streamlit en Python 3.12

Función: Interfaz interactiva de usuario, visualización de scoring individual, análisis de variables críticas y panel de impacto ROI.



**Puerto
8000**

Backend / API REST

Tecnología: FastAPI en Python 3.12

Función: Endpoints independientes (/health, /predict) para integración programática. Todo el ecosistema orquestado nativamente mediante docker-compose.

Demo del Dashboard: Navegando el Producto Mínimo Viable



Interfaz incrustando métricas operativas y predictivas en tiempo real.


Dentro de la Mente del Modelo: La Anatomía de un Cliente Premium

1

Intensidad de Entrega:

Un alto número de pedidos entregados y artículos totales impulsan fuertemente la puntuación hacia la clasificación Premium.

- delivered_orders
- max_payment_installments
- total_items
- top_category_cama_mesa_banho
- top_category_is_high_value
- reviews_per_order
- avg_delivery_days
- credit_card_flag
- main_payment_type_boleto
- installments_gt_1_flag
- avg_estimated_delivery_days
- top_category_telefonia



2

Comportamiento de Pago:

El alto uso de cuotas indica poder adquisitivo y se correlaciona fuertemente con el estatus Premium.

3

Selección de Productos:

Las compras en categorías específicas de gama alta son indicadores masivos de valores de ticket premium.

El modelo confirma que el estatus Premium en un entorno de compra única está impulsado por la densidad del carrito, el uso de cuotas y las categorías de productos de alto valor.

Explicabilidad (SHAP): La Anatomía del Cliente Premium

delivered_orders
(Intensidad transaccional)

max_payment_installments
(Capacidad crediticia y cuotas)

total_items
(Volumen de productos)

top_category_is_high_value
(Afinidad por relojes, electrónica)

**Score
Premium**

Potencial de Alto Valor

Mensaje Clave: La caja de cristal. El modelo es completamente transparente y acciona sobre comportamiento logístico y transaccional real, sin basarse en suposiciones ocultas.

Estándar de Calidad: El Rendimiento Metodológico Base (Sprint 3)

ROC-AUC

0.8081

Gini

0.6162

Recall (Umbral 0.55)

0.6041

Precision (Umbral 0.55)

0.5225

Postulado Científico: Esta validación temporal representa la verdad fundamental y el estándar de generalización puro del modelo frente a una población heterogénea.
Es el baseline metodológico inmutable.

Validación Operativa: Desempeño sobre Backtest Formal (Agosto de 2018)

ROC-AUC

0.9876

Gini: 0.9751

Precision | Recall

43.80% | 56.11%

F1: 49.20%



Lectura Recomendada del Resultado

- El backtest muestra una separabilidad operativa muy alta en agosto de 2018.
- No se interpreta como reemplazo directo de la validación temporal de Sprint 3.
- Su valor principal es demostrar scoring reproducible, integración del MVP y utilidad para la capa comercial.

Validación Operativa: Separabilidad en el Escenario Holdout (Sprint 4)

Holdout 3M ROC-AUC

0.9872

Gini: 0.9745

Holdout 3M

Precision | Recall

43.10% | 57.06%



Nota Metodológica Crítica

- El elevado ROC-AUC **NO** es una mejora milagrosa ni un sobreajuste del modelo.
- Se debe a una mayor separabilidad estructural del escenario operativo mensual.
- El volumen truncado de transacciones facilita drásticamente la discriminación técnica frente a clientes inactivos.
- El modelo mantiene su robustez integrativa, pero el éxito real debe juzgarse estrictamente por el ROI comercial.


Impacto Financiero: El Verdadero Valor del Modelo

	Campaña Masiva	Campaña Optimizada
Clientes Impactados	96,096	1,659
Costo de Campaña	BRL 1.44M	BRL 24,885
Utilidad Neta	Pérdida BRL -1.29M	Ganancia BRL +60,915
ROI Final	-89.57%	+244.79%

El modelo genera una reducción del 98.27% en costos de marketing, logrando un ahorro neto documentado de BRL 1.41 Millones.

Capacidad de priorización comercial del score

Gain y lift sobre el backtest formal de agosto de 2018



Cientes evaluados	96,096
Premium reales	1,253
Tasa base premium	1.30%
Captura acumulada top 10%	100.0%
Tasa premium en decil 1	13.04%
Lift del decil 1	10.00x
Lift acumulado top 20%	5.00x

El ranking del modelo concentra a los clientes premium reales en los primeros deciles. El primer decil captura el 100% de los premium reales observados en el backtest. La tasa premium del primer decil (13.04%) es muy superior a la tasa base global (1.30%). Esto demuestra utilidad para focalización comercial y reducción del desperdicio de campaña. **“El score ordena correctamente el valor comercial esperado y permite concentrar la acción en una fracción pequeña de clientes.”**


Esta lámina debe leerse como evidencia operativa de priorización en backtest, no como sustituto de la validación temporal principal de Sprint 3.

Detalle técnico de gain/lift por deciles

Backtest formal de agosto de 2018

decile	cases	responses	premium_rate_pct	cum_responses	gain_pct	lift	cum_lift
1	9,610	1,253	13.04%	1,253	100.0%	10.00	10.00
2	~9,610	0	0.00%	1,253	100.0%	0.00	5.00
3	~9,610	0	0.00%	1,253	100.0%	0.00	3.33
4	~9,610	0	0.00%	1,253	100.0%	0.00	2.50
5	~9,610	0	0.00%	1,253	100.0%	0.00	2.00
6	~9,610	0	0.00%	1,253	100.0%	0.00	1.67
7	~9,610	0	0.00%	1,253	100.0%	0.00	1.43
8	~9,610	0	0.00%	1,253	100.0%	0.00	1.25
9	~9,610	0	0.00%	1,253	100.0%	0.00	1.11
10	~9,610	0	0.00%	1,253	100.0%	0.00	1.00
Total	96,096	1,253	1.30%				

El **decil 1** concentra 1,253 premium reales. La tasa premium del decil 1 es 13.04%. El lift del primer decil es 10.00x. La captura acumulada del top 10% alcanza 100.0%.



Esta tabla respalda la capacidad de priorización comercial del score en el backtest, pero no sustituye la validación metodológica principal del Sprint 3.

¿Cuándo reentrenar el modelo?

Criterio operativo de monitoreo y revisión del MVP

1. Monitorear desempeño

- No por calendario, sino por evidencia
- Revisar si caen Gini, ROC-AUC, precision o recall en ventanas nuevas

2. Detectar deterioro o drift

- Revisar si cae el ROI de la campaña focalizada
- Revisar cambios fuertes en la tasa premium predicha
- Revisar drift en variables clave del negocio

Variables clave: delivered_orders, total_items, max_payment_installments, customer_state, top_category_is_high_value

3. Revisar / recalibrar / reentrenar

- Regla inicial: alerta amarilla si Gini cae más de 20% respecto al baseline
- Revisión prioritaria si además cae ROI o cambia bruscamente la tasa premium predicha
- Reentrenar solo con una ventana temporal nueva y completa

Reentrenamos cuando la data nueva deja de parecerse a la historia con la que aprendió el modelo y eso empieza a degradar su capacidad de segmentar con valor de negocio.

Privacidad, gobernanza y uso responsable del modelo

Qué datos excluimos, qué señales utilizamos y qué controles proponemos



1. Qué no usamos

- No usamos identificadores personales directos en el entrenamiento.
- Se excluyeron variables como **customer_unique_id**, **customer_city** y **customer_zip_code_prefix**.
- No usamos datos financieros sensibles directos como números de tarjeta o cuentas bancarias.



2. Qué sí usamos

- Usamos variables agregadas de comportamiento comercial y transaccional.
- Ejemplos: **delivered_orders**, **total_items**, **top_category_is_high_value**.
- También usamos algunas señales de contexto como **customer_state**, **main_payment_type** y **max_payment_installments**.



3. Riesgos residuales

- Algunas variables pueden actuar como proxies de sesgo geográfico o financiero.
- Por eso deben monitorearse efectos no deseados en segmentación y priorización.



4. Control operativo

- El score debe usarse como apoyo a decisión comercial.
- No debe operar como automatización ciega.
- Se requiere supervisión humana, versionado del artefacto y monitoreo periódico.

El modelo reduce exposición a datos sensibles directos, pero no elimina por completo el riesgo de sesgo. Por eso proponemos monitoreo continuo y uso supervisado.

“ El modelo no entrena con datos sensibles directos, pero sí requiere monitoreo de proxies y supervisión humana. ”

Conclusiones y Próximos Pasos en MLOps

Hito 1: Estado Actual

MVP listo para producción.
Pipeline reutilizable operando
en contenedores Docker y
respaldando un ROI de +244%.

Hito 2: Monitoreo MLOps

Integración futura con
herramientas como MLflow
para versionado de
experimentos y observabilidad
real del data drift.

Hito 3: Reentrenamiento Automatizado

Flujos CI/CD para ejecutar
entrenamientos mensuales,
capturando la evolución
dinámica del
comportamiento y logística.

“ El Sprint 4 demuestra que el clasificador final ya está integrado, puede explicarse en vivo, y genera una recomendación comercial con sentido económico. ”