

Reporte de Sprint 4: Integración del MVP, Validación Holdout, Explicabilidad SHAP y Storytelling de Negocio

Marcelo de la Quintana, Gaston Nina, y Gerick Toro
Módulo de Implementación de Soluciones de Inteligencia Artificial
Maestría en Inteligencia Artificial y Ciencia de Datos

Resumen—Este informe documenta el Sprint 4 del proyecto de identificación de clientes premium sobre Olist, cuyo objetivo fue transformar el modelo final del Sprint 3 en un MVP defendible para Demo Day, integrando un pipeline reproducible de scoring sobre holdout, un dashboard en Streamlit, una API mínima, explicabilidad local y global, y una narrativa de impacto de negocio. El pipeline reutilizado genera `holdout_features_selected.parquet` alineado al esquema esperado por `modelo_final.pkl`. Sobre el holdout temporal se obtuvo un ROC-AUC de 0.9872, Gini de 0.9745, Precision de 43.10 %, Recall de 57.06 % y F1-Score de 49.11 %. Sin embargo, se argumenta que este desempeño no debe interpretarse de forma aislada como evidencia absoluta de generalización superior, ya que la etiqueta premium se define por gasto acumulado y el holdout presenta una población mucho más desbalanceada y estructuralmente más fácil que la validación de Sprint 3. A nivel de negocio, el modelo permite pasar de una campaña masiva con ROI estimado de -89.57 % a una campaña focalizada con ROI de +244.79 %, reduciendo el costo comercial en BRL 1,416,555.00. La explicabilidad se reforzó con contribuciones locales nativas de LightGBM y un SHAP Summary Plot tipo beeswarm, mientras que la capa de gobernanza quedó documentada en términos de sesgo logístico, señales de pago y supervisión humana.

Index Terms—Streamlit, FastAPI, Docker, Holdout Temporal, SHAP, LightGBM, Clasificación Supervisada, Clientes Premium, Olist, ROI, Gobernanza de Modelos.

I. INTRODUCCIÓN

EL Sprint 3 cerró con un modelo LightGBM tuneado serializado como `modelo_final.pkl`, seleccionado por maximizar la discriminación global sobre el split temporal de desarrollo y validación (`last_purchase < / ≥ 2018-07-01`), alcanzando $ROC-AUC_{val} = 0,8081$ y $Gini_{val} = 0,6162$. El objetivo del **Sprint 4** fue convertir ese artefacto analítico en una demostración funcional y defendible para negocio, preservando reproducibilidad, explicabilidad y trazabilidad.

El sprint se organizó en cuatro bloques:

1. Reutilización del pipeline para generar un dataset de scoring en `holdout_3m`.
2. Construcción del MVP en Streamlit y empaquetado reproducible en Docker.
3. Validación analítica sobre holdout con métricas técnicas, explicabilidad y simulación financiera.
4. Consolidación de narrativa ejecutiva, gobernanza y checklist de Demo Day.

La pregunta central del Sprint 4 ya no es “¿qué modelo rinde mejor?”, sino *¿podemos demostrar que el modelo final es integrable, explicable y útil para una decisión comercial realista?*

I-A. Angulo correcto de defensa

Para exposición académica y ejecutiva conviene fijar una distinción explícita: **Sprint 3** es la validación metodológica principal del clasificador, mientras que **Sprint 4** es la validación de producto mínimo viable. Por ello, el resultado más importante del sprint no es “mejorar” artificialmente el AUC, sino demostrar cinco capacidades concretas:

1. scoring reproducible sobre una ventana holdout;
2. integración funcional en dashboard y API;
3. explicabilidad local y global con SHAP;
4. traducción del score a impacto económico mediante ROI;
5. documentación de riesgos, gobernanza y límites metodológicos.

II. ARQUITECTURA DEL SPRINT 4

II-A. Flujo técnico

El flujo implementado sigue la secuencia:

`holdout_3m` → `master_table_holdout`
→ `holdout_features_rfm` → `holdout_features_selected`




Figura 1. Arquitectura final del MVP de Sprint 4. El pipeline prepara el dataset de scoring, mientras dashboard y API consumen el mismo artefacto del modelo dentro de contenedores separados.

Los entregables principales del sprint son:

- `holdout_features_selected.parquet` y `demo_sample_scoring.parquet` en `data/processed/`.
- `app.py` del dashboard en `app/dashboard/`.
- `main.py` de la API en `app/api/`.
- Figuras principales del sprint en `reports/figures/`, incluyendo ROI y SHAP beeswarm.

II-B. Compatibilidad operativa

Tras regenerar el artefacto `modelo_final.pkl` en un entorno actualizado, los contenedores del dashboard y la API se fijaron en Python 3.12. La validación realizada en Sprint 4 comprobó que el modelo se carga correctamente dentro de ambos contenedores Docker y mantiene compatibilidad operativa con el MVP.

III. VALIDACIÓN HOLDOUT

III-A. Definición del escenario holdout

El holdout de Sprint 4 utiliza una ventana temporal separada (`holdout_3m`) y aplica el mismo umbral de negocio persistido en desarrollo: un cliente es premium si su gasto acumulado en la ventana es mayor o igual al umbral fijo de BRL **197.01** (P80 del conjunto de desarrollo).

Cuadro I
RESUMEN DEL HOLDOUT SPRINT 4

Métrica	Valor
Cientes evaluados	96,096
Cientes premium reales	1,253
Tasa premium real	1.30 %
Cientes predichos como premium	1,659
Tasa premium predicha	1.73 %
Umbral de clasificación	0.55

III-B. Métricas técnicas

Cuadro II
MÉTRICAS TÉCNICAS SOBRE HOLDOUT

Métrica	Valor
ROC-AUC	0.9872
Gini	0.9745
Precision	43.10 %
Recall	57.06 %
F1-Score	49.11 %

III-C. Interpretación crítica del ROC-AUC alto

Aunque el ROC-AUC de **0.9872** es notablemente superior al ROC-AUC de validación del Sprint 3 (**0.8081**), esta diferencia no debe interpretarse automáticamente como una mejora masiva de generalización del modelo. Tampoco es evidencia directa de sobreajuste clásico, ya que el overfitting se manifiesta cuando el rendimiento en datos no vistos cae respecto al desarrollo, no cuando aumenta.

La explicación más plausible combina dos factores metodológicos:

1. **La tarea en holdout es más fácil.** La población holdout contiene una gran masa de clientes sin actividad o con actividad mínima en la ventana, mientras que el segmento premium exige al menos gasto suficiente para superar el umbral fijo. Esta separación estructural facilita la discriminación.
2. **La etiqueta premium está muy acoplada a señales transaccionales.** Aunque se excluyeron variables de leakage directo como `total_spent` y `avg_ticket`, se conservaron proxies fuertes del comportamiento de gasto, como `delivered_orders`, `total_items`, `max_payment_installments` y `top_category_is_high_value`. Por ello, el modelo no memoriza el target, pero sí resuelve una tarea muy cercana al criterio de negocio que define la etiqueta.

III-D. Nota sobre truncamiento temporal del holdout

Aunque el split técnico fue definido como agosto–octubre de 2018, la distribución real de órdenes del holdout está concentrada casi por completo en agosto, con muy pocos registros útiles en septiembre y octubre. En consecuencia:

- no interpretamos esos dos meses como tendencia de crecimiento o cambio estructural del negocio;
- no usamos la cola septiembre–octubre para construir narrativa comercial;
- tratamos el holdout principalmente como validación final de integración, scoring y separabilidad operativa.

En consecuencia, para defensa académica se recomienda presentar este AUC como **evidencia de fuerte separabilidad del escenario holdout**, no como prueba única de superioridad absoluta del modelo. La comparación metodológicamente correcta del modelo sigue siendo la validación temporal del Sprint 3.

IV. EXPLICABILIDAD

IV-A. SHAP local y global

La demo incorpora explicabilidad local por cliente mediante `pred_contrib=True` de LightGBM sobre el espacio transformado por el ColumnTransformer. Adicionalmente, se generó un SHAP Summary Plot tipo beeswarm sobre una muestra del holdout.

Las variables líderes del SHAP global son coherentes con la lógica del caso:

- `delivered_orders`
- `max_payment_installments`
- `total_items`
- `top_category_is_high_value`

Esto refuerza la interpretación de que el modelo identifica intensidad transaccional, participación en categorías de alto valor y comportamiento de pago como señales dominantes del segmento premium.




Figura 2. SHAP Summary Plot (beeswarm) sobre una muestra de 3,000 clientes del holdout. Las variables más influyentes son predominantemente transaccionales y de valor comercial.

V. IMPACTO DE NEGOCIO

V-A. Simulación financiera

Se compararon dos estrategias:

1. **Campaña masiva:** contactar a toda la base.
2. **Campaña focalizada:** contactar solo a clientes con probabilidad $\geq 0,55$.

Cuadro III
COMPARATIVA DE ESTRATEGIAS COMERCIALES

Métrica	Masiva	Modelo
Clientes contactados	96,096	1,659
Costo de campaña	BRL 1,441,440.00	BRL 24,885.00
Ingreso por conversiones	BRL 150,360.00	BRL 85,800.00
Utilidad neta	BRL -1,291,080.00	BRL 60,915.00
ROI	-89.57 %	+244.79 %




Figura 3. Matriz de confusión sobre holdout y comparativa de ROI entre campaña masiva y campaña optimizada por modelo.

VI. GOBERNANZA Y RIESGOS

El Sprint 4 también consolidó una lectura de riesgo para uso responsable del MVP:

- **Sesgo logístico/geográfico:** variables de tiempos de entrega y estimación pueden capturar desigualdades regionales.
- **Sesgo por bancarización:** señales como cuotas y método de pago pueden favorecer perfiles con mayor acceso financiero.
- **Necesidad de supervisión humana:** el score se propone como apoyo a priorización comercial, no como criterio automático único.

VII. CONCLUSIONES

El Sprint 4 logró cerrar el ciclo de integración entre analítica y producto:

1. Se reutilizó el pipeline para construir un dataset holdout alineado al artefacto oficial.
2. Se implementó un MVP en Streamlit y una API mínima reproducibles en Docker.
3. Se validó el modelo sobre holdout con métricas técnicas, explicabilidad y simulación de impacto.
4. Se documentaron riesgos éticos, pitch ejecutivo y checklist final de cierre.

La principal advertencia metodológica del sprint es que el holdout presenta un escenario más separable que la validación del Sprint 3. Por ello, el ROC-AUC de 0.9872 debe defenderse como resultado de un problema más fácil y de una etiqueta fuertemente ligada al comportamiento transaccional, no como una prueba aislada de superioridad definitiva del modelo.

REFERENCIAS

- [1] M. de la Quintana, G. Nina, y G. Toro, "Reporte de Sprint 3: Hiperparametrización, Selección del Modelo Final y Exportación del Clasificador de Clientes Premium," *Informe Técnico, Módulo de Implementación de Soluciones de IA, Maestría en IA y Ciencia de Datos*, junio 2026.
- [2] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.