

Reporte de Sprint 4: Integración del MVP, Validación Backtest, Explicabilidad SHAP y Storytelling de Negocio

Marcelo de la Quintana, Gaston Nina, y Gerick Toro
Módulo de Implementación de Soluciones de Inteligencia Artificial
Maestría en Inteligencia Artificial y Ciencia de Datos

Resumen—Este informe documenta el Sprint 4 del proyecto de identificación de clientes premium sobre Olist, cuyo objetivo fue transformar el modelo final del Sprint 3 en un MVP defendible para Demo Day, integrando un pipeline reproducible de scoring sobre una ventana de backtest, un dashboard en Streamlit, una API mínima, explicabilidad local y global, y una narrativa de impacto de negocio. El pipeline reutilizado genera `backtest_features_selected.parquet` alineado al esquema esperado por `modelo_final.pkl`. Sobre el backtest de agosto de 2018 se obtuvo un ROC-AUC de 0.9876, Gini de 0.9751, Precision de 43.80 %, Recall de 56.11 % y F1-Score de 49.20 %. Sin embargo, se argumenta que este desempeño no debe interpretarse de forma aislada como evidencia absoluta de generalización superior, ya que la etiqueta premium se define por gasto acumulado y el backtest presenta una población mucho más desbalanceada y estructuralmente más fácil que la validación de Sprint 3. A nivel de negocio, el modelo permite pasar de una campaña masiva con ROI estimado de -89.57 % a una campaña focalizada con ROI de +250.40 %, reduciendo el costo comercial en BRL 1,417,365.00. La explicabilidad se reforzó con contribuciones locales nativas de LightGBM y un SHAP Summary Plot tipo beeswarm, mientras que la capa de gobernanza quedó documentada en términos de sesgo logístico, señales de pago y supervisión humana.

Index Terms—Streamlit, FastAPI, Docker, Backtest Temporal, SHAP, LightGBM, Clasificación Supervisada, Clientes Premium, Olist, ROI, Gobernanza de Modelos.

I. INTRODUCCIÓN

EL Sprint 3 cerró con un modelo LightGBM tuneado serializado como `modelo_final.pkl`, seleccionado por maximizar la discriminación global sobre el split temporal de desarrollo y validación (`last_purchase < / ≥ 2018-07-01`), alcanzando $ROC-AUC_{val} = 0,8081$ y $Gini_{val} = 0,6162$. El objetivo del **Sprint 4** fue convertir ese artefacto analítico en una demostración funcional y defendible para negocio, preservando reproducibilidad, explicabilidad y trazabilidad.

El sprint se organizó en cuatro bloques:

1. Reutilización del pipeline para generar un dataset de scoring en backtest.
2. Construcción del MVP en Streamlit y empaquetado reproducible en Docker.
3. Validación analítica sobre backtest con métricas técnicas, explicabilidad y simulación financiera.
4. Consolidación de narrativa ejecutiva, gobernanza y checklist de Demo Day.

La pregunta central del Sprint 4 ya no es “¿qué modelo rinde mejor?”, sino *¿podemos demostrar que el modelo final es integrable, explicable y útil para una decisión comercial realista?*

I-A. Angulo correcto de defensa

Para exposición académica y ejecutiva conviene fijar una distinción explícita: **Sprint 3** es la validación metodológica principal del clasificador, mientras que **Sprint 4** es la validación de producto mínimo viable. Por ello, el resultado más importante del sprint no es “mejorar” artificialmente el AUC, sino demostrar cinco capacidades concretas:

1. scoring reproducible sobre una ventana de backtest;
2. integración funcional en dashboard y API;
3. explicabilidad local y global con SHAP;
4. traducción del score a impacto económico mediante ROI;
5. documentación de riesgos, gobernanza y límites metodológicos.

II. ARQUITECTURA DEL SPRINT 4

II-A. Flujo técnico

El flujo implementado sigue la secuencia:

`backtest` → `master_table_backtest`

→ `backtest_features_rfm` → `backtest_features_selected`




Figura 1. Arquitectura final del MVP de Sprint 4. El pipeline prepara el dataset de scoring, mientras dashboard y API consumen el mismo artefacto del modelo dentro de contenedores separados.

Los entregables principales del sprint son:

- `backtest_features_selected.parquet` y `demo_sample_scoring.parquet` en `data/processed/`.
- `app.py` del dashboard en `app/dashboard/`.
- `main.py` de la API en `app/api/`.
- Figuras principales del sprint en `reports/figures/`, incluyendo ROI y SHAP beeswarm.

II-B. Compatibilidad operativa

Tras regenerar el artefacto `modelo_final.pkl` en un entorno actualizado, los contenedores del dashboard y la API se fijaron en Python 3.12. La validación realizada en Sprint 4 comprobó que el modelo se carga correctamente dentro de ambos contenedores Docker y mantiene compatibilidad operativa con el MVP.

III. VALIDACIÓN BACKTEST

III-A. Definición del escenario backtest

Aunque el split técnico histórico del proyecto conservó una partición `holdout_3m` entre agosto y octubre de 2018, la distribución real de órdenes mostró que septiembre y octubre están prácticamente vacíos. Para evitar una evaluación final apoyada en una cola truncada, Sprint 4 formaliza como backtest la ventana completa de **agosto de 2018** (`backtest`) y aplica el mismo umbral de negocio persistido en desarrollo: un cliente es premium si su gasto acumulado en la ventana es mayor o igual al umbral fijo de BRL **197.01** (P80 del conjunto de desarrollo).

Cuadro I
RESUMEN DEL BACKTEST SPRINT 4

Métrica	Valor
Cientes evaluados	96,096
Cientes premium reales	1,253
Tasa premium real	1.30 %
Cientes predichos como premium	1,605
Tasa premium predicha	1.67 %
Umbral de clasificación	0.55

III-B. Métricas técnicas

Cuadro II
MÉTRICAS TÉCNICAS SOBRE BACKTEST

Métrica	Valor
ROC-AUC	0.9876
Gini	0.9751
Precision	43.80 %
Recall	56.11 %
F1-Score	49.20 %

III-C. Interpretación crítica del ROC-AUC alto

Aunque el ROC-AUC de **0.9876** es notablemente superior al ROC-AUC de validación del Sprint 3 (**0.8081**), esta diferencia no debe interpretarse automáticamente como una mejora masiva de generalización del modelo. Tampoco es evidencia directa de sobreajuste clásico, ya que el overfitting se manifiesta cuando el rendimiento en datos no vistos cae respecto al desarrollo, no cuando aumenta.

La explicación más plausible combina dos factores metodológicos:

1. **La tarea en backtest es más fácil.** La población evaluada contiene una gran masa de clientes sin actividad o con actividad mínima en la ventana, mientras que el segmento premium exige al menos gasto suficiente para superar el umbral fijo. Esta separación estructural facilita la discriminación.
2. **La etiqueta premium está muy acoplada a señales transaccionales.** Aunque se excluyeron variables de leakage directo como `total_spent` y `avg_ticket`, se conservaron proxies fuertes del comportamiento de gasto, como `delivered_orders`, `total_items`, `max_payment_installments` y `top_category_is_high_value`. Por ello, el modelo no memoriza el target, pero sí resuelve una tarea muy cercana al criterio de negocio que define la etiqueta.

III-D. Nota sobre el holdout historico de 3 meses

El split `holdout_3m` se mantiene en el repositorio por compatibilidad y trazabilidad del trabajo previo, pero no se usa ya como escenario oficial de evaluación final del Sprint 4. La razón es que septiembre y octubre de 2018 solo aportan 20 órdenes combinadas, por lo que no constituyen una ventana seria para juzgar desempeño. En consecuencia:

- no interpretamos septiembre y octubre como evidencia de tendencia comercial;
- no usamos esa cola para sostener métricas finales del modelo;
- tratamos agosto de 2018 como backtest oficial y dejamos el holdout de tres meses como antecedente del recorte temporal.

En consecuencia, para defensa académica se recomienda presentar este AUC como **evidencia de fuerte separabilidad del escenario backtest**, no como prueba única de superioridad absoluta del modelo. La comparación metodológicamente correcta del modelo sigue siendo la validación temporal del Sprint 3.

IV. EXPLICABILIDAD

IV-A. SHAP local y global

La demo incorpora explicabilidad local por cliente mediante `pred_contrib=True` de LightGBM sobre el espacio transformado por el `ColumnTransformer`. Adicionalmente, se generó un SHAP Summary Plot tipo beeswarm sobre una muestra del backtest.

Las variables líderes del SHAP global son coherentes con la lógica del caso:




Figura 2. SHAP Summary Plot (beeswarm) sobre una muestra de 3,000 clientes del backtest. Las variables más influyentes son predominantemente transaccionales y de valor comercial.

- delivered_orders
- max_payment_installments
- total_items
- top_category_is_high_value

Esto refuerza la interpretación de que el modelo identifica intensidad transaccional, participación en categorías de alto valor y comportamiento de pago como señales dominantes del segmento premium.

V. IMPACTO DE NEGOCIO

V-A. Simulación financiera

Se compararon dos estrategias:

1. **Campaña masiva:** contactar a toda la base.
2. **Campaña focalizada:** contactar solo a clientes con probabilidad $\geq 0,55$.

Cuadro III
COMPARATIVA DE ESTRATEGIAS COMERCIALES

Métrica	Masiva	Modelo
Clientes contactados	96,096	1,605
Costo de campaña	BRL 1,441,440.00	BRL 24,075.00
Ingreso por conversiones	BRL 150,360.00	BRL 84,360.00
Utilidad neta	BRL -1,291,080.00	BRL 60,285.00
ROI	-89.57 %	+250.40 %

V-B. Lift y capacidad de priorización del ranking

Además del umbral operativo, el docente solicitó validar la capacidad del score como ranking comercial. Para esta lectura usamos solo los **clientes activos en agosto de 2018** ($\text{total_orders} > 0$), con el fin de evaluar la priorización sobre la población realmente operativa de la ventana backtest. Luego ordenamos esos clientes por probabilidad predicha descendente y los dividimos en **10 deciles del mismo tamaño**. En cada decil medimos cuántos clientes premium reales aparecen, cuántos se acumulan y cuál es el *lift* respecto a una selección aleatoria.

Esta lectura es especialmente valiosa para negocio porque responde una pregunta distinta a la de Precision/Recall: *si solo*

priorizamos el 10 %, 20 % o 30 % de la base con mayor score, qué proporción del segmento premium logramos capturar?

Cuadro IV
TABLA DE DECILES LIFT/GAIN SOBRE CLIENTES ACTIVOS DE AGOSTO 2018

Decil	Casos	Premium	% premium decil	Premium acum.	Gain acum. (%)	Lift	Lift acum.
1	646	405	62.69	405	32.32	3.23	3.23
2	646	216	33.44	621	49.56	1.72	2.48
3	646	167	25.85	788	62.89	1.33	2.10
4	646	109	16.87	897	71.59	0.87	1.79
5	646	91	14.09	988	78.85	0.73	1.58
6	646	89	13.78	1,077	85.95	0.71	1.43
7	646	62	9.60	1,139	90.90	0.49	1.30
8	646	62	9.60	1,201	95.85	0.49	1.20
9	646	37	5.73	1,238	98.80	0.30	1.10
10	646	15	2.32	1,253	100.00	0.12	1.00

Los resultados muestran una priorización fuerte pero más realista sobre la población activa. Entre **6,460 clientes activos** y **1,253 premium reales**, el **primer decil** captura **32.32 %** de todos los premium y alcanza una tasa premium interna de **62.69 %**, frente a una tasa base de **19.40 %**. Esto equivale a un **lift de 3.23x** en el tramo más alto del ranking. Al ampliar la cobertura al **20 %** superior de clientes activos, el modelo ya captura **49.56 %** de los premium reales. La conclusión es más defendible para negocio: el score no es perfecto, pero **sí ordena de forma útil a los clientes activos**, concentrando una fracción sustantiva del valor comercial en los primeros deciles.




Figura 3. Responses por decil y curvas acumuladas de gain/lift sobre clientes activos en agosto de 2018. El ranking concentra una porción importante de premium reales en los primeros deciles sin caer en la separación extrema observada sobre la base completa.




Figura 4. Matriz de confusión sobre backtest y comparativa de ROI entre campaña masiva y campaña optimizada por modelo.

VI. MONITOREO OPERATIVO Y CRITERIO DE REENTRENAMIENTO

El MVP de Sprint 4 no debe interpretarse como un artefacto estático válido para cualquier momento futuro. Dado que el modelo fue entrenado sobre comportamiento histórico, su utilidad depende de que la relación entre señales transaccionales, contexto logístico y definición de cliente premium se mantenga razonablemente estable en el tiempo.

VI-A. Qué debe monitorearse

En una operación posterior al Demo Day, el dashboard o una capa de monitoreo debería revisar al menos cuatro grupos de señales:

- **Desempeño discriminativo:** métricas como ROC-AUC, Gini, Precision y Recall sobre ventanas nuevas no usadas en entrenamiento.
- **Impacto comercial:** ROI observado o estimado de la campaña focalizada frente a una estrategia masiva o baseline operativo.
- **Estabilidad poblacional:** tasa predicha de clientes premium y volumen de clientes efectivamente priorizados.
- **Drift de variables clave:** cambios relevantes en `delivered_orders`, `total_items`, `max_payment_installments`, `customer_state` o `top_category_is_high_value`.

VI-B. Cuándo revisar o reentrenar

La recomendación metodológica es **no reentrenar por calendario fijo**, sino por evidencia de deterioro sostenido. Como criterio operativo inicial para el MVP, puede proponerse:

- **Alerta amarilla:** caída de Gini superior al 20 % respecto al baseline de referencia o descenso consistente de precision comercial.
- **Alerta roja:** Gini por debajo de un umbral mínimo acordado con negocio, acompañado por deterioro del ROI o por un cambio brusco en la tasa premium predicha.
- **Revisión obligatoria:** drift simultáneo en varias variables dominantes del modelo, aun si la métrica agregada todavía luce aceptable.

VI-C. Base temporal correcta para reentrenar

Si se confirma degradación, el nuevo entrenamiento debe construirse sobre una **ventana temporal más reciente y completa**, separada del período usado por el artefacto vigente. Esta

distinción es importante: mostrar resultados mes a mes sobre historia ya vista por el modelo puede servir como backtesting descriptivo del negocio, pero no como prueba suficiente de vigencia futura. En consecuencia, el reentrenamiento debe apoyarse en datos nuevos y comparables, no solo en recombinar la misma historia conocida.

VII. GOBERNANZA Y RIESGOS

El Sprint 4 también consolidó una lectura de riesgo para uso responsable del MVP:

- **Sesgo logístico/geográfico:** variables de tiempos de entrega y estimación pueden capturar desigualdades regionales.
- **Sesgo por bancarización:** señales como cuotas y método de pago pueden favorecer perfiles con mayor acceso financiero.
- **Necesidad de supervisión humana:** el score se propone como apoyo a priorización comercial, no como criterio automático único.

VIII. CONCLUSIONES

El Sprint 4 logró cerrar el ciclo de integración entre analítica y producto:

1. Se reutilizó el pipeline para construir un dataset de backtest alineado al artefacto oficial.
2. Se implementó un MVP en Streamlit y una API mínima reproducibles en Docker.
3. Se validó el modelo sobre backtest con métricas técnicas, explicabilidad y simulación de impacto.
4. Se documentaron riesgos éticos, pitch ejecutivo y checklist final de cierre.

La principal advertencia metodológica del sprint es que el backtest presenta un escenario más separable que la validación del Sprint 3. Por ello, el ROC-AUC de 0.9876 debe defenderse como resultado de un problema más fácil y de una etiqueta fuertemente ligada al comportamiento transaccional, no como una prueba aislada de superioridad definitiva del modelo.

REFERENCIAS

- [1] M. de la Quintana, G. Nina, y G. Toro, "Reporte de Sprint 3: Hiperparametrización, Selección del Modelo Final y Exportación del Clasificador de Clientes Premium," *Informe Técnico, Módulo de Implementación de Soluciones de IA, Maestría en IA y Ciencia de Datos*, junio 2026.
- [2] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.